Fachhochschule Nordwestschweiz
Hochschule für Technik

Application Performance Management

Performance Testing im Web

Michael Faes

Rückblick: High Availability & Failover

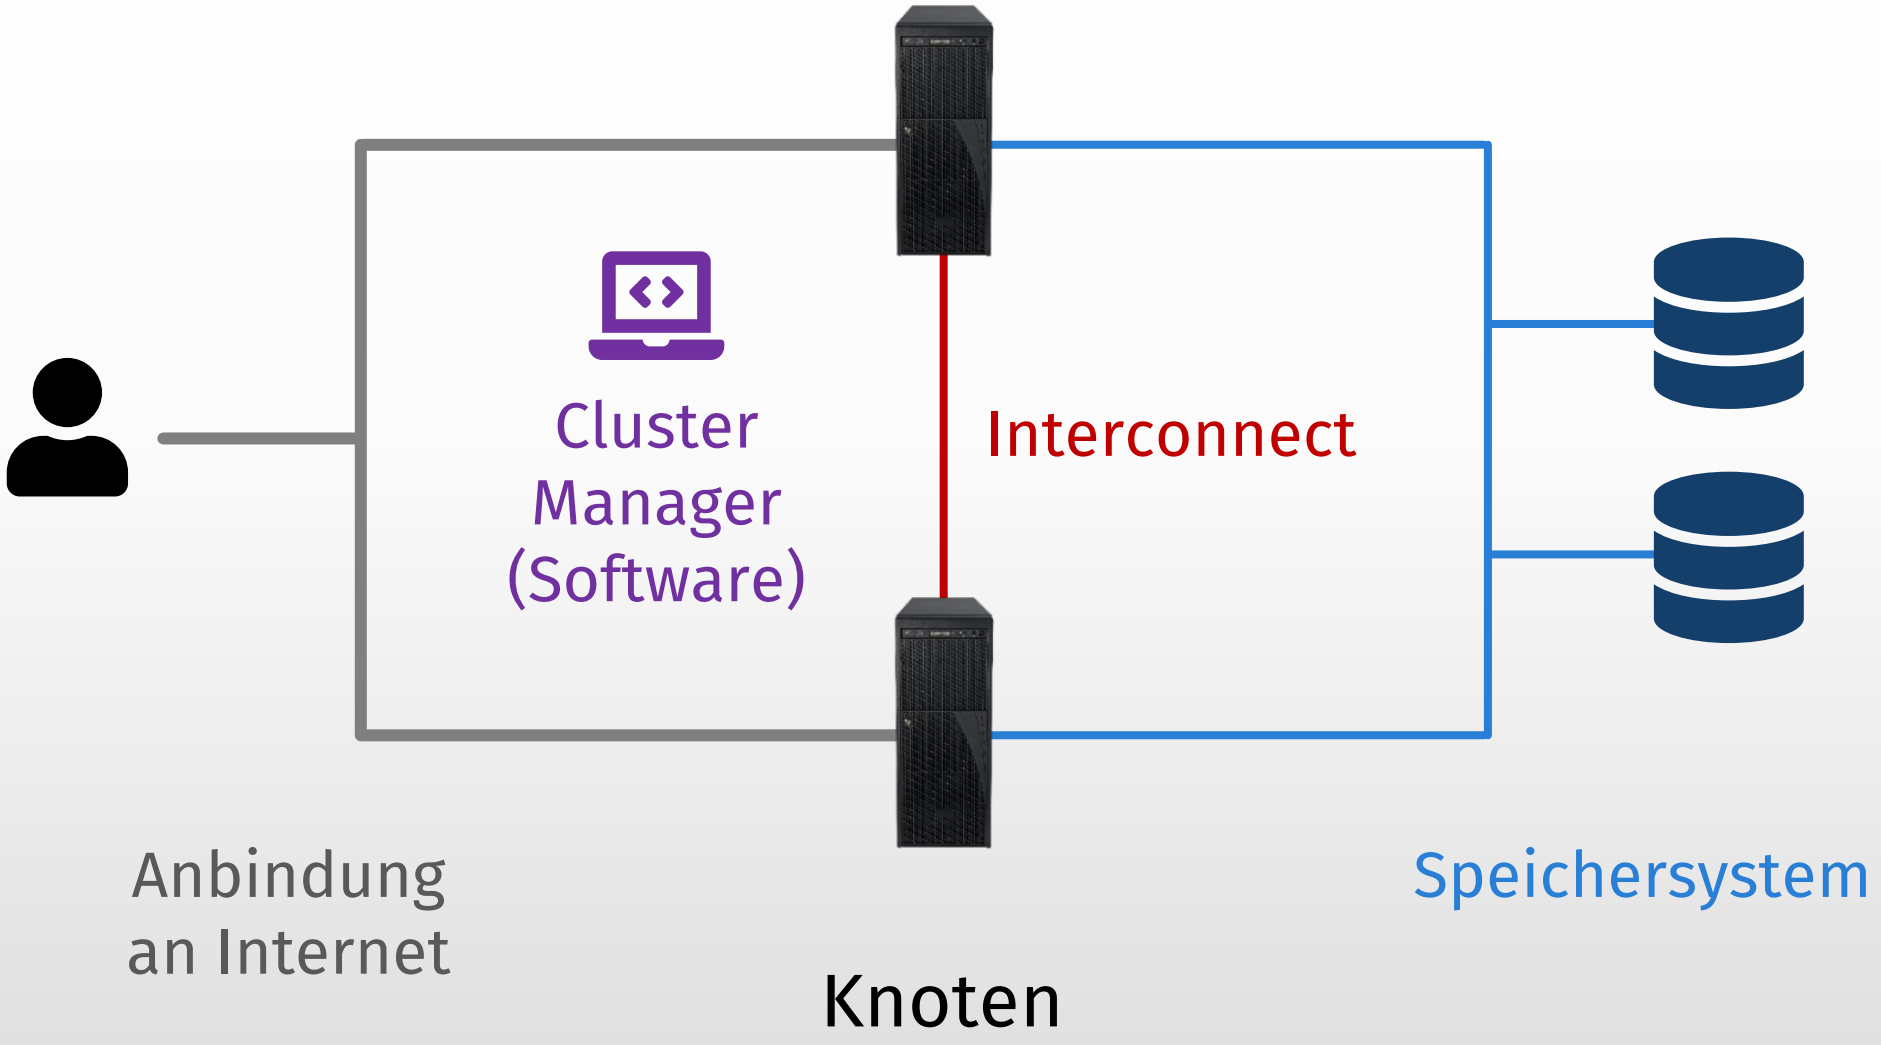

Übersicht Woche 11

1. Rückblick High Availability
2. Performance messen im Web
   - Endbenutzerantwortzeit
   - Aktives & passives Monitoring
   - Workload Characterization
   - Apache JMeter
3. Performance Testing
   - Arten von Performance Tests
   - Last- & Stressverhalten von Apps
4. Übung

Performance Messen im Web

Rückblick: Antwortzeit

Wichtigste Metrik aus Sicht des Benutzers: *Antwortzeit*

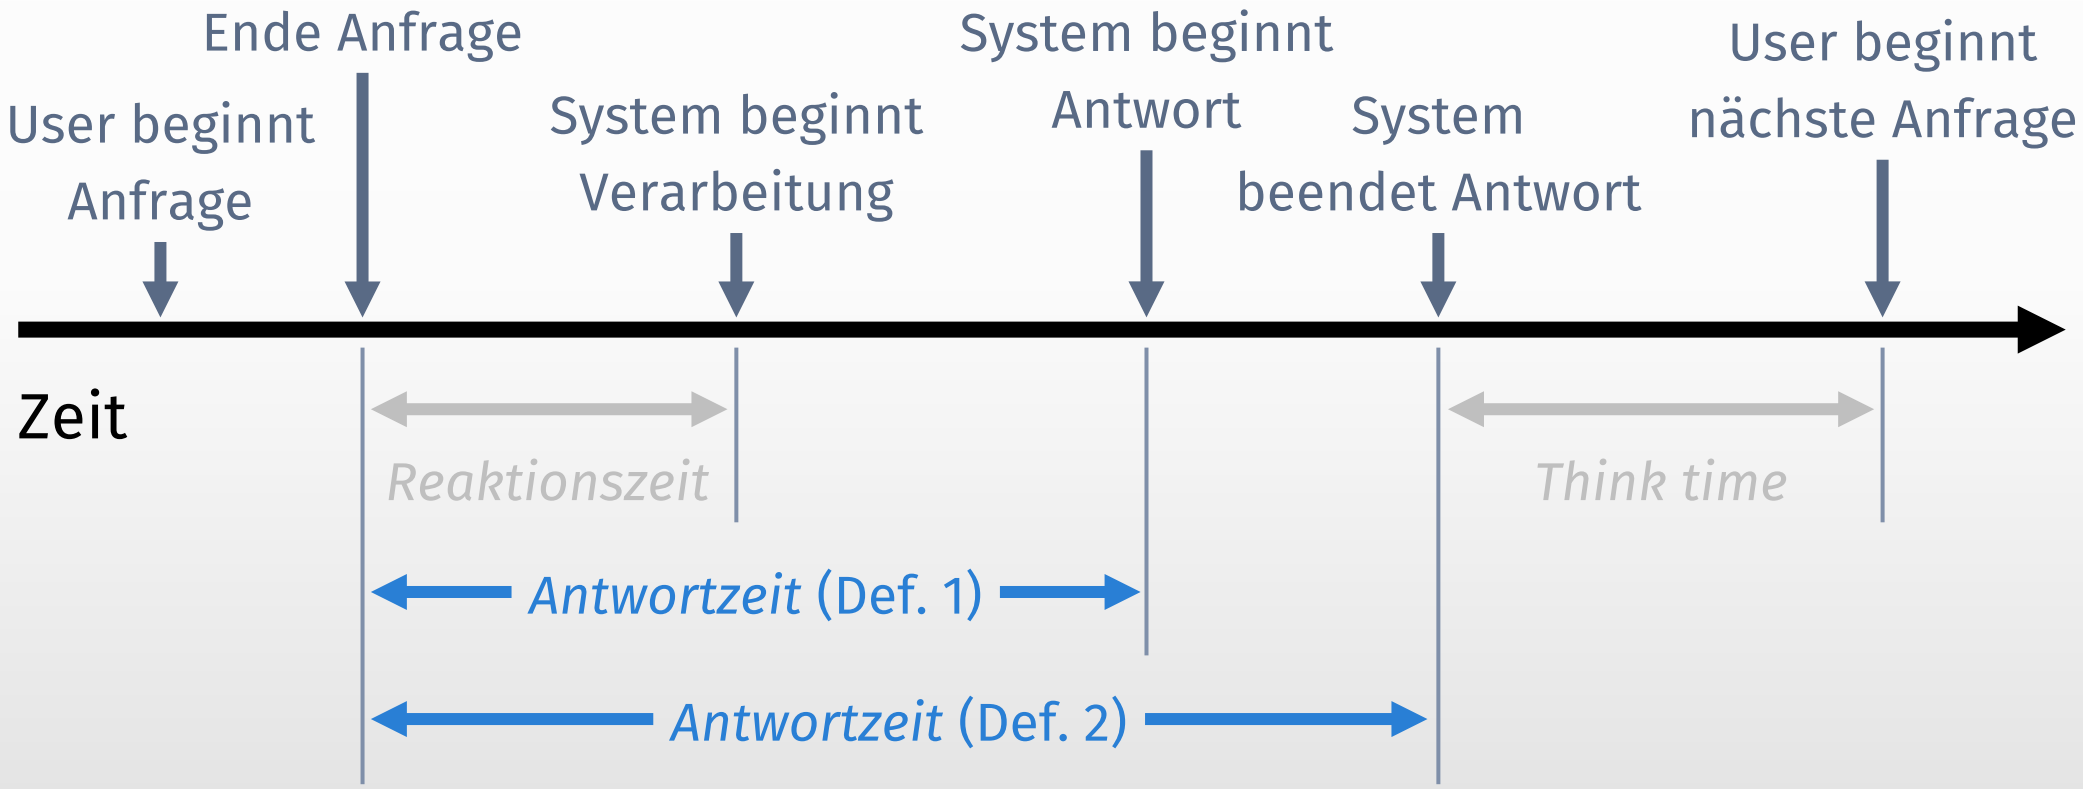

Definitionen sind alle **aus der Sicht des Systems!**

Systemgrenze und Zeitmessung

Wo ist Grenze des «Systems»? Wo messen wir Antwortzeit?

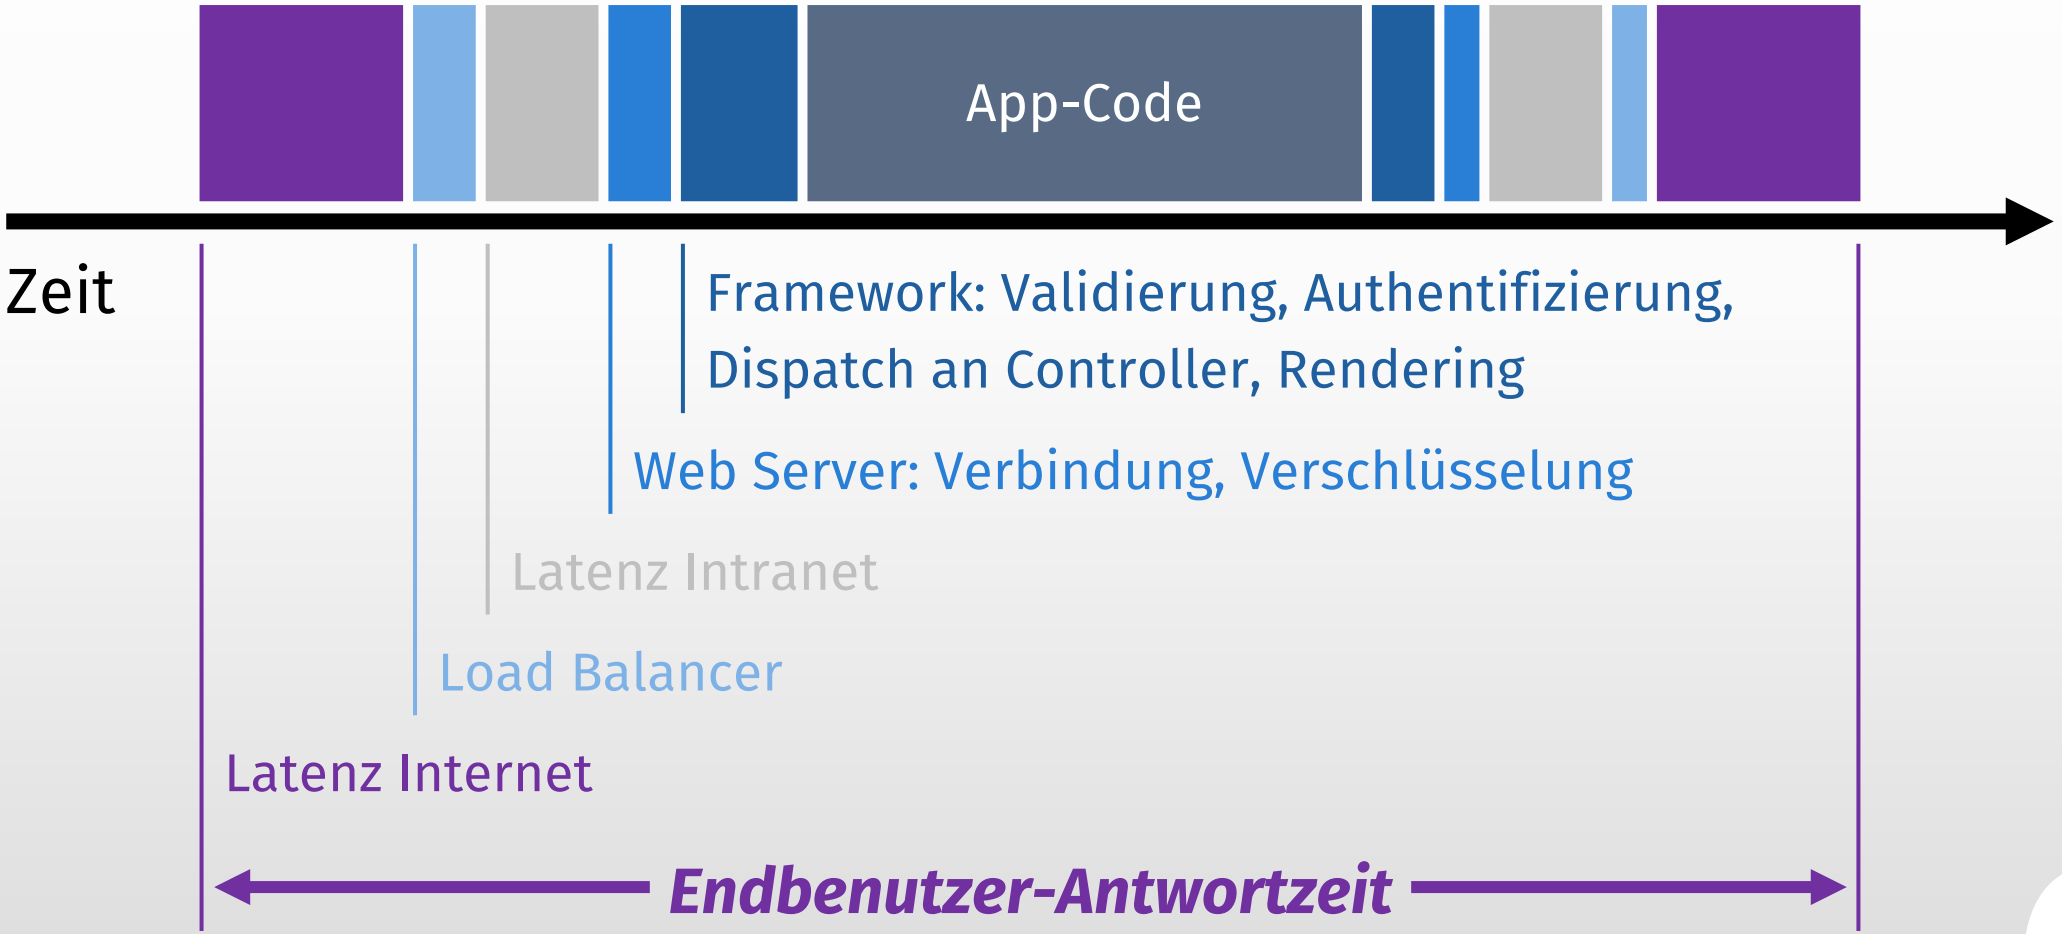

Endbenutzer-Antwortzeit

Kann objektiv gemessen werden, aber wird subjektiv wahrgenommen.

> *Die empfundene durchschnittliche Antwortzeit entspricht nicht dem Durchschnitt, sondern dem 0.9-Quantil, das heisst dem Wert, der grösser ist als 90% aller beobachteten Antwortzeiten.*
>
> — Arnold O. Allen, Introduction to Computer Performance Analysis with Mathematica (Academic Press, San Diego, CA, 1994)

Wie messen / abschätzen?

- Passives Monitoring
- Aktives Monitoring

Passives Monitoring

Beobachten von Benutzer-Anfragen, z. B. mit Netzwerk-Sniffer

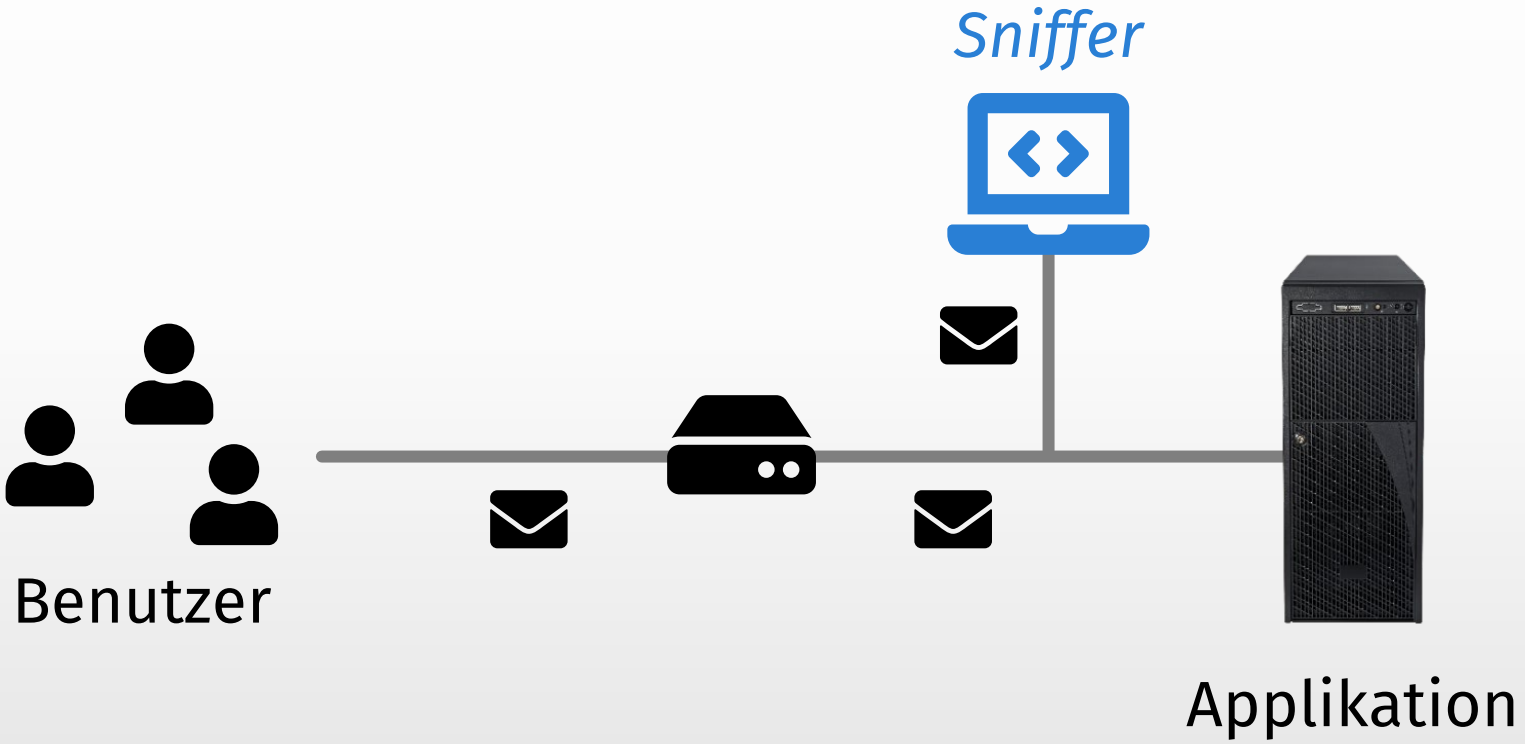

Aktives Monitoring

Ein *Lastgenerator* erzeugt synthetische Anfragen, die «typisches» Benutzerverhalten simulieren:

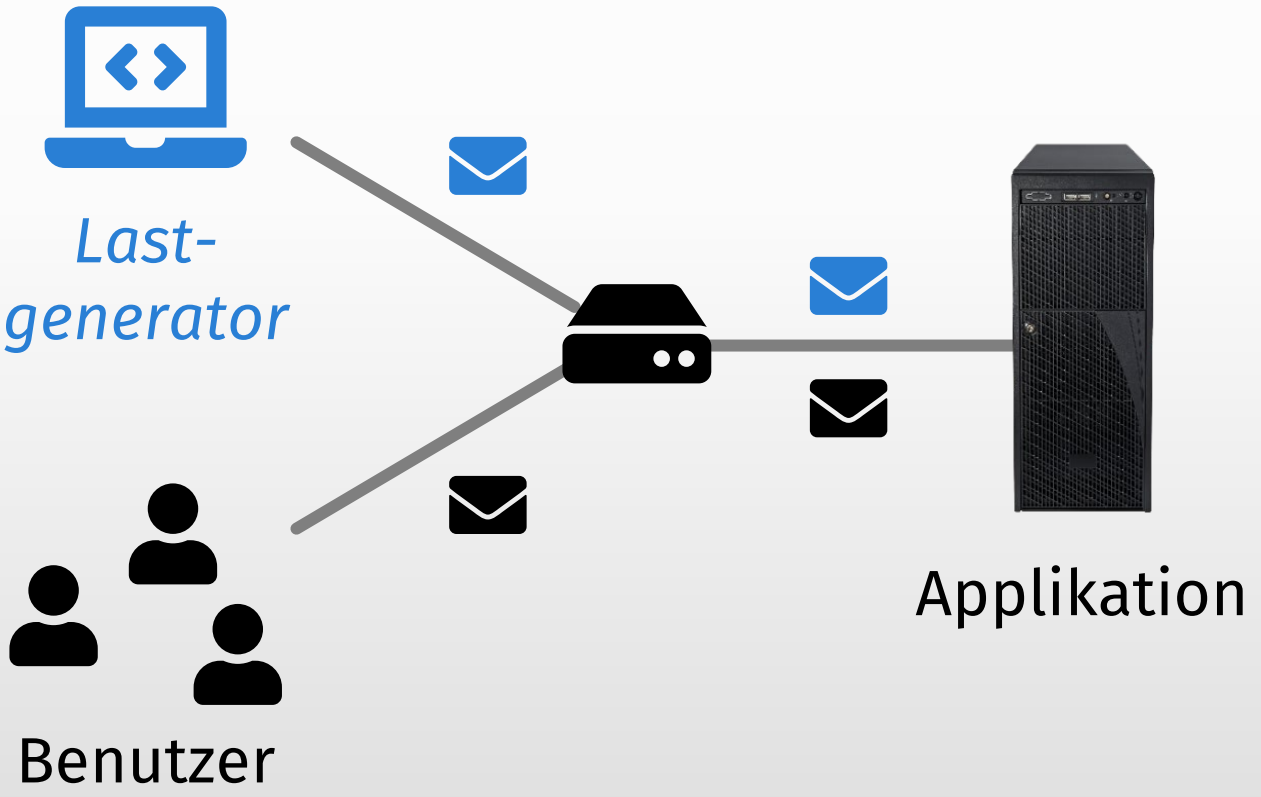

Aktives vs. passives Monitoring

Aktiv

- Misst vollständige Endbenutzer-Antwortzeit (…)
- Belastet System mit zusätzlichen Anfragen
- Keine echten Users nötig, flexibler Einsatz in Entwicklung
- Benötigt Modell für «typisches» Benutzerverhalten

Passiv

- Misst nur Teil der Endbenutzer-Antwortzeit
- Keine Zusatzbelastung des Systems
- Benötigt echte Users und laufendes Produktiv-System
- Kein Modell nötig, beobachtet *echtes* Benutzerverhalten

→ *Workload Characterization*

Auswahl des Workloads

Einer der wichtigsten Teile von Performance-Analyse: der *Workload*.

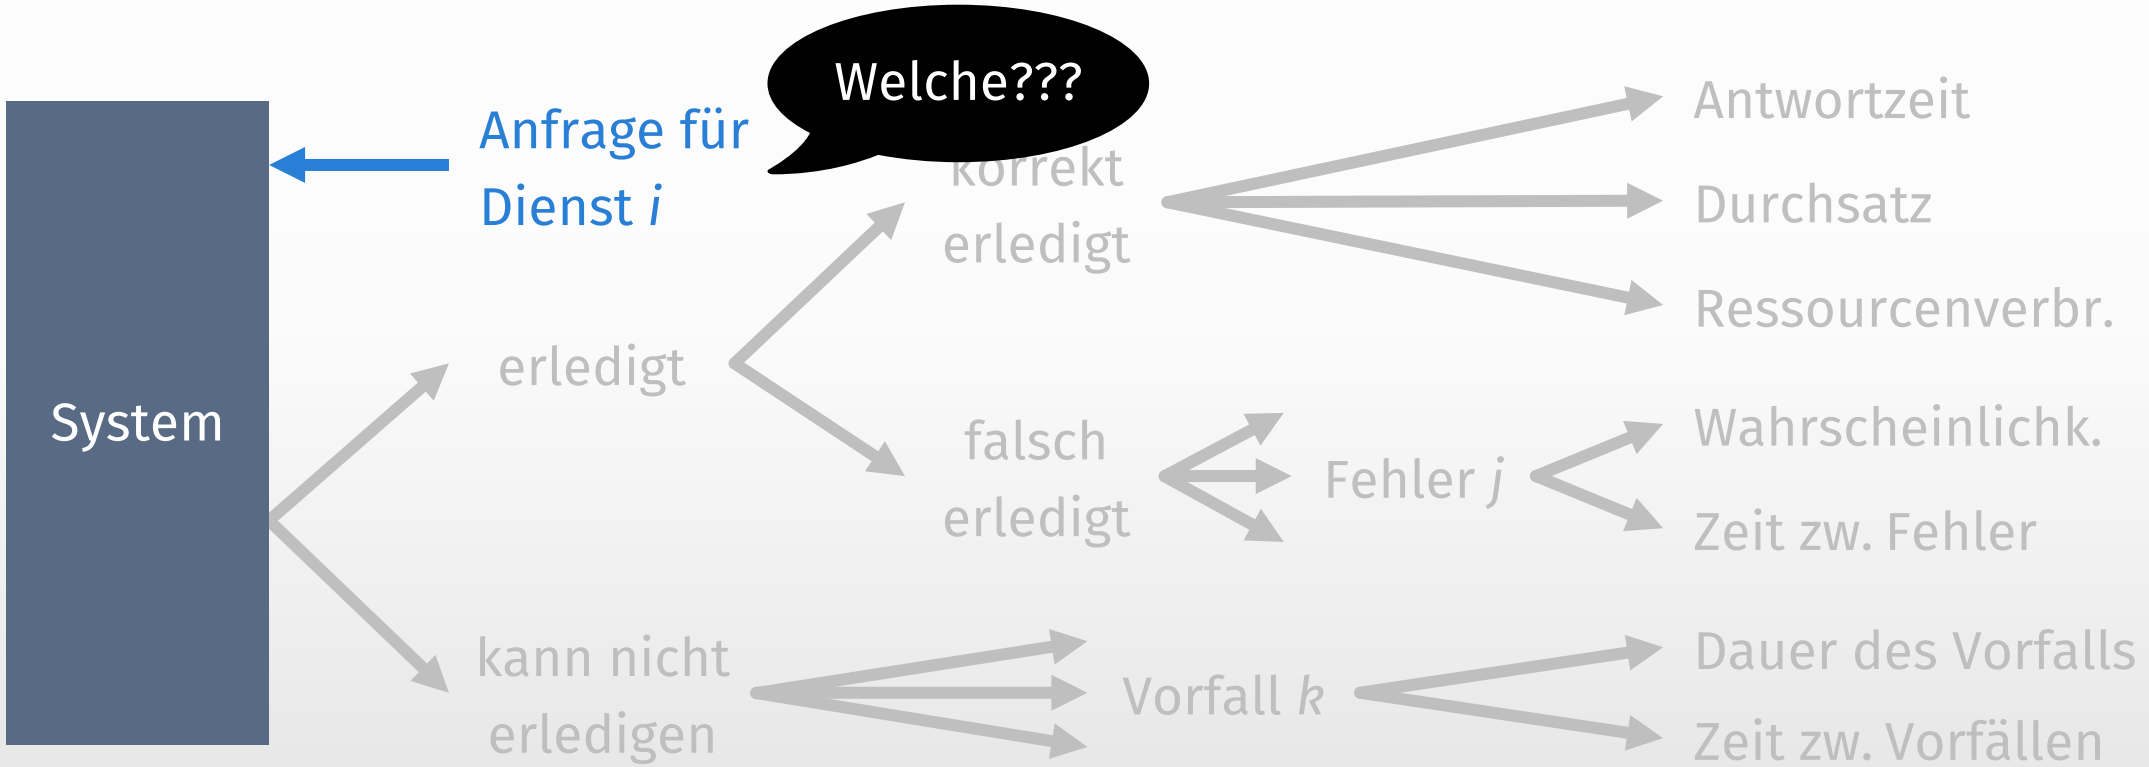

Ausgewählte/beobachtete Last hat grossen Einfluss auf Resultate.

Workload Selection / Characterization

Aktives Monitoring braucht *Modell* für Benutzerverhalten.

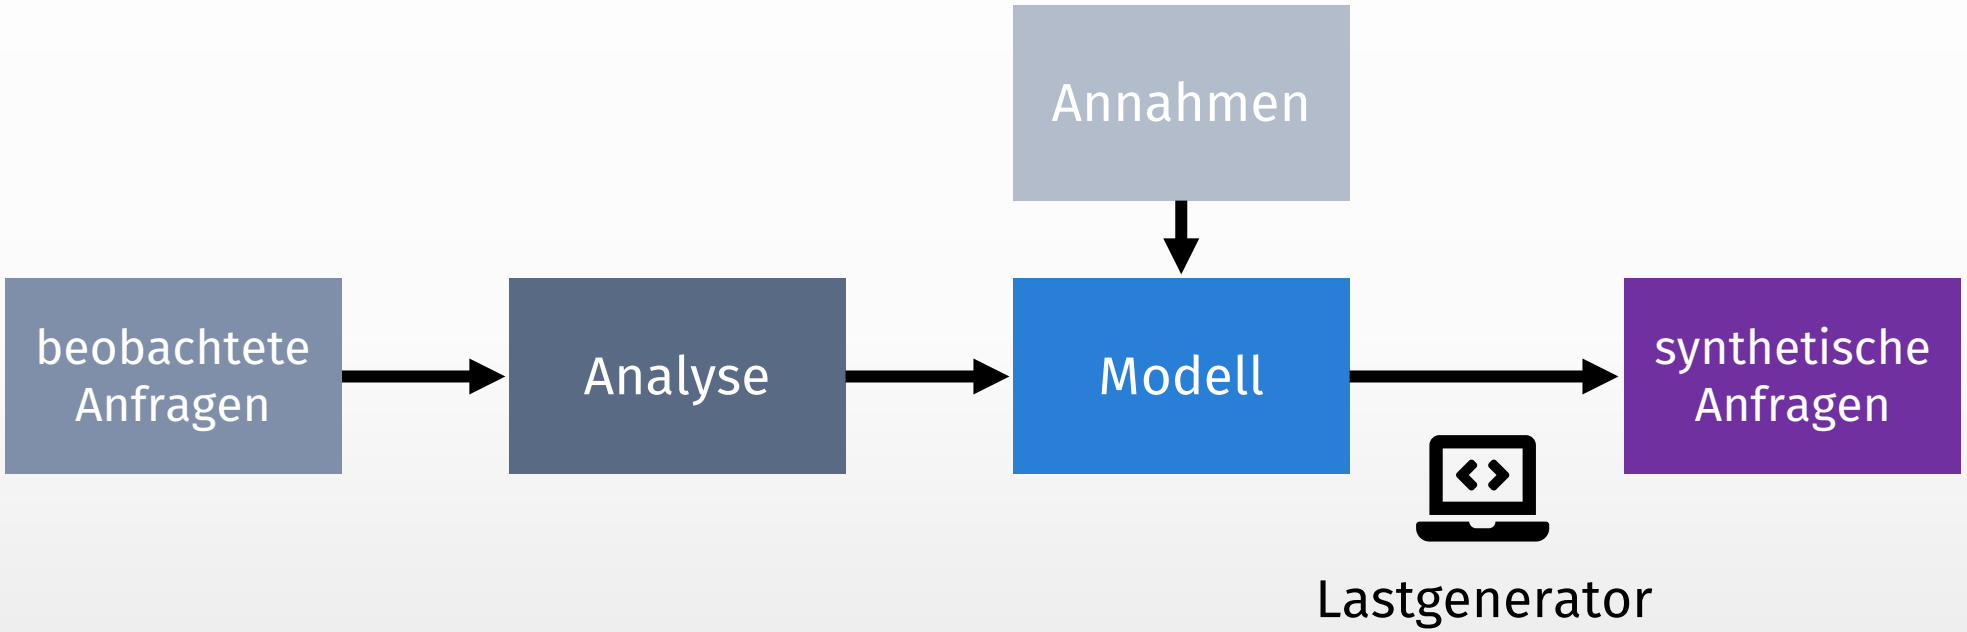

Beispiel-Modell (sehr einfach):

Mach GET-Anfrage an /shop. Warte 30 Sek. Wiederhole.

Workload besteht z. B. aus 50 solcher Benutzer mit 20 Wiederholungen.

Überlegungen bei der Auswahl und Charakterisierung von Workloads:

1. Komplexität

- Häufigste Anfrage
- Mischung von Anfragen, mit definierter Häufigkeit
- *Sequenzen von Anfragen*, inklusive Think times
- …

Vor-/
Nachteile?

2. Aktualität: Workload soll *aktuellem* Benutzerverhalten entsprechen.

Herausforderungen:

- Können Verhalten immer nur für bestimmte Situation beobachten.
  Kann abhängig sein von Tageszeit, Jahreszeit, Wetter, Ereignissen, …
- Verhalten kann sogar abhängig sein von App-Performance!
  Verhalten beeinflusst Performance und umgekehrt!

3. Variabilität: Variables Benutzerverhalten kann gut durch *Zufall* simuliert werden. Aber Resultate sollen auch möglichst *reproduzierbar* sein! Viel Zufall führt zu weniger Reproduzierbarkeit…

4. Scope: Wie bei funktionalen Tests gibt es verschiedene Grössenordnungen zum «Testen» von Performance:

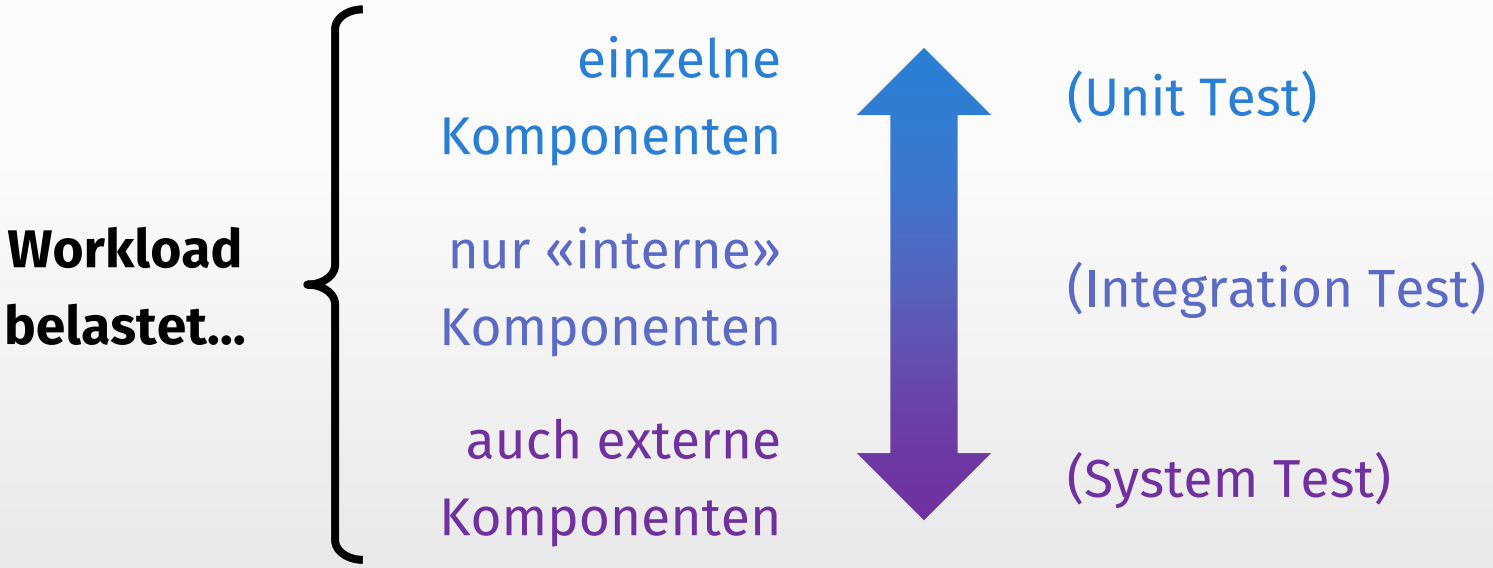

5. Last-Level: System unter «niedriger», «erwarteter» oder «hoher» Last testen? Oder sogar zum Zusammenbruch bringen? → **Zweck!**

Apache JMeter

Apache JMeter: Lastgenerator-Software.
Generiert Anfragen und misst Antwortzeit & Durchsatz

Unterstützung für Web-Apps, Web-Dienste, Datenbanken, Verbindungen

- Protokolle: HTTP(S), REST, SOAP, FTP, LDAP, JDBC, JMS, SMTP, IMAP, TCP, …

Möglichkeiten für Workload-Definition:

- GUI
- Scripting
- Browser-Recording

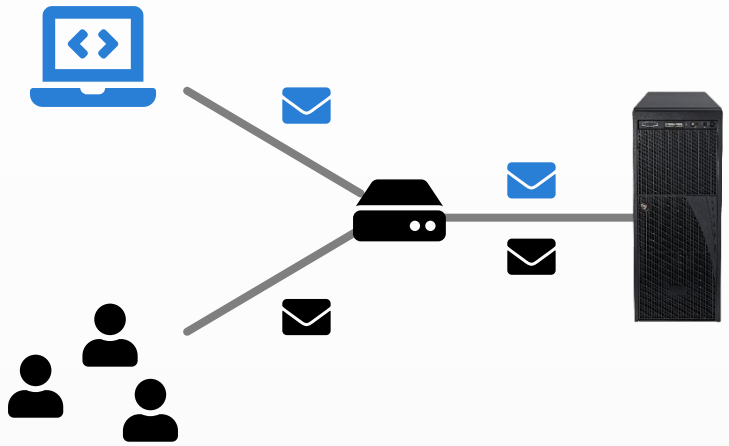

Verwendung von JMeter (Live)

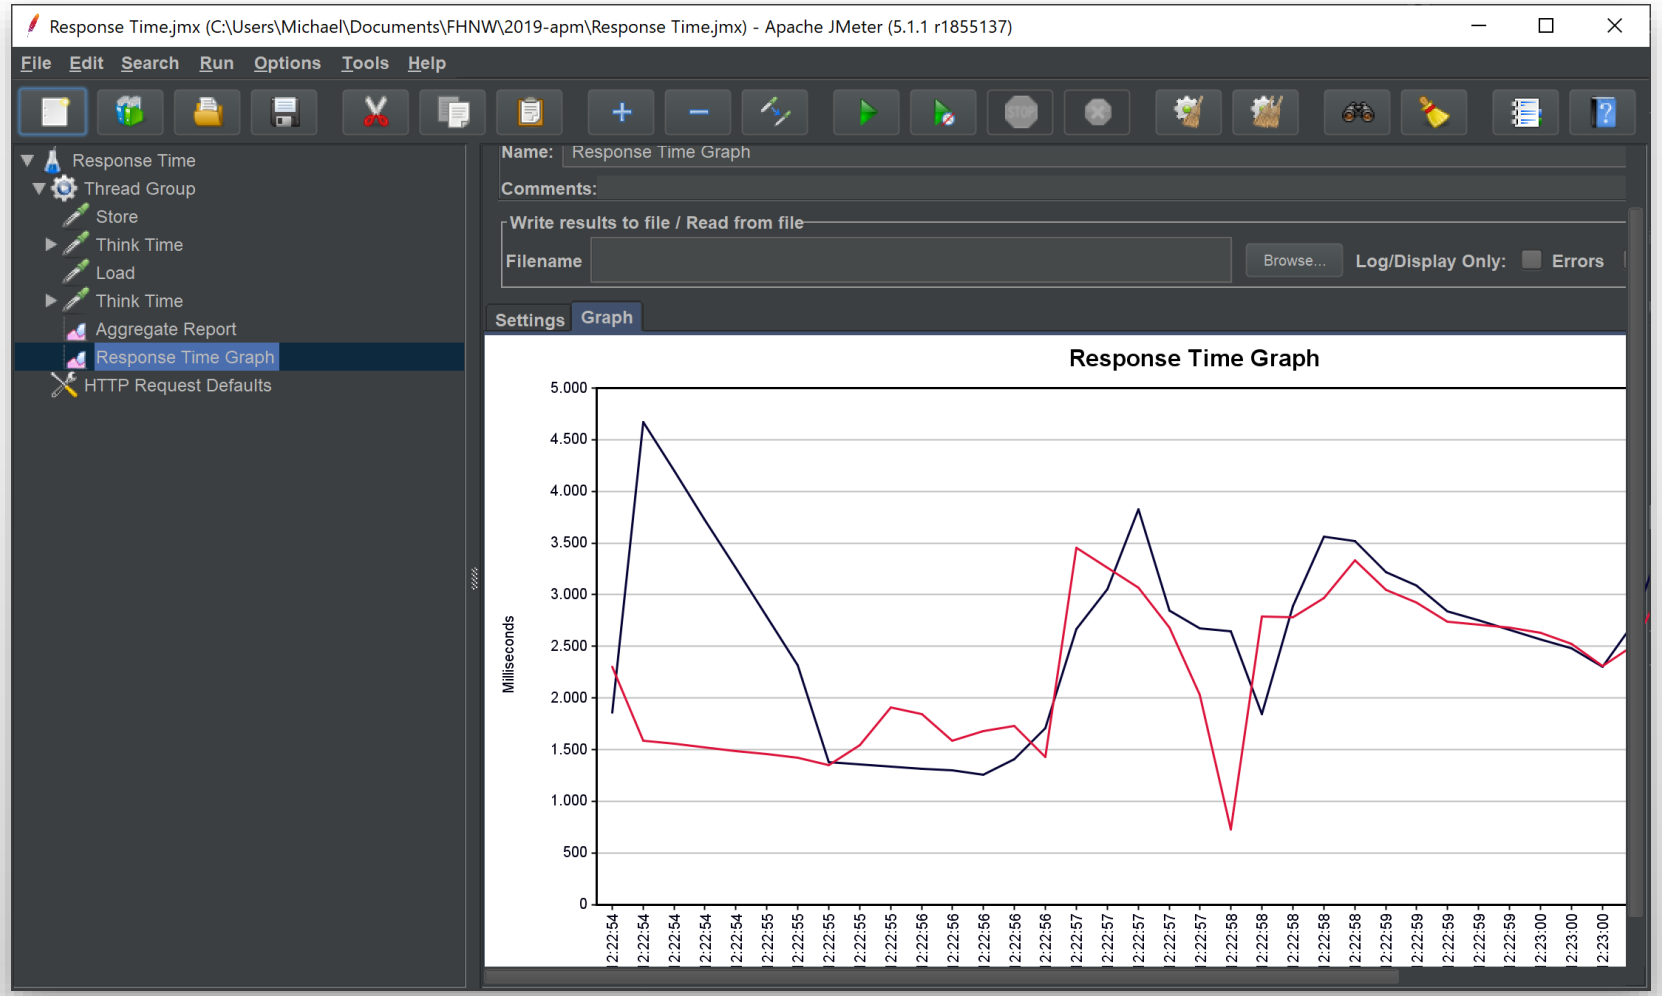

Performance Testing

Performance «testen»

Haben gesehen, wie man Performance *misst* und *auswertet*

- Erste Semesterhälfte: einzelne Code-Stücke, *Single-Node*-Apps
- Heute: (verteilte) Web-Apps

Nächster Schritt: *Performance testen*. Unterschied zu *Messung*?

Engineering-Ansatz!

- Requirements-Analyse
- Planung
- Entwicklung von Test-Suite
- Dokumentation
- Reporting
- …

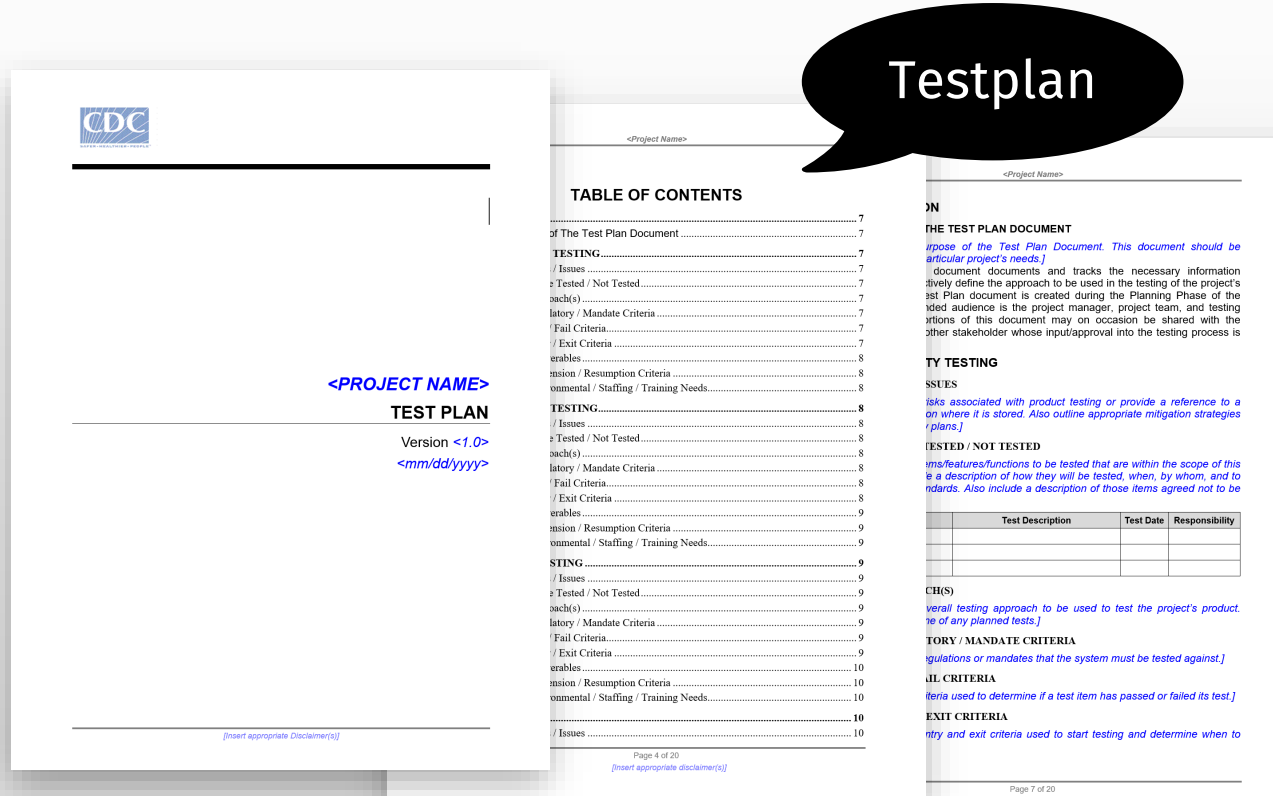

Performance Testing

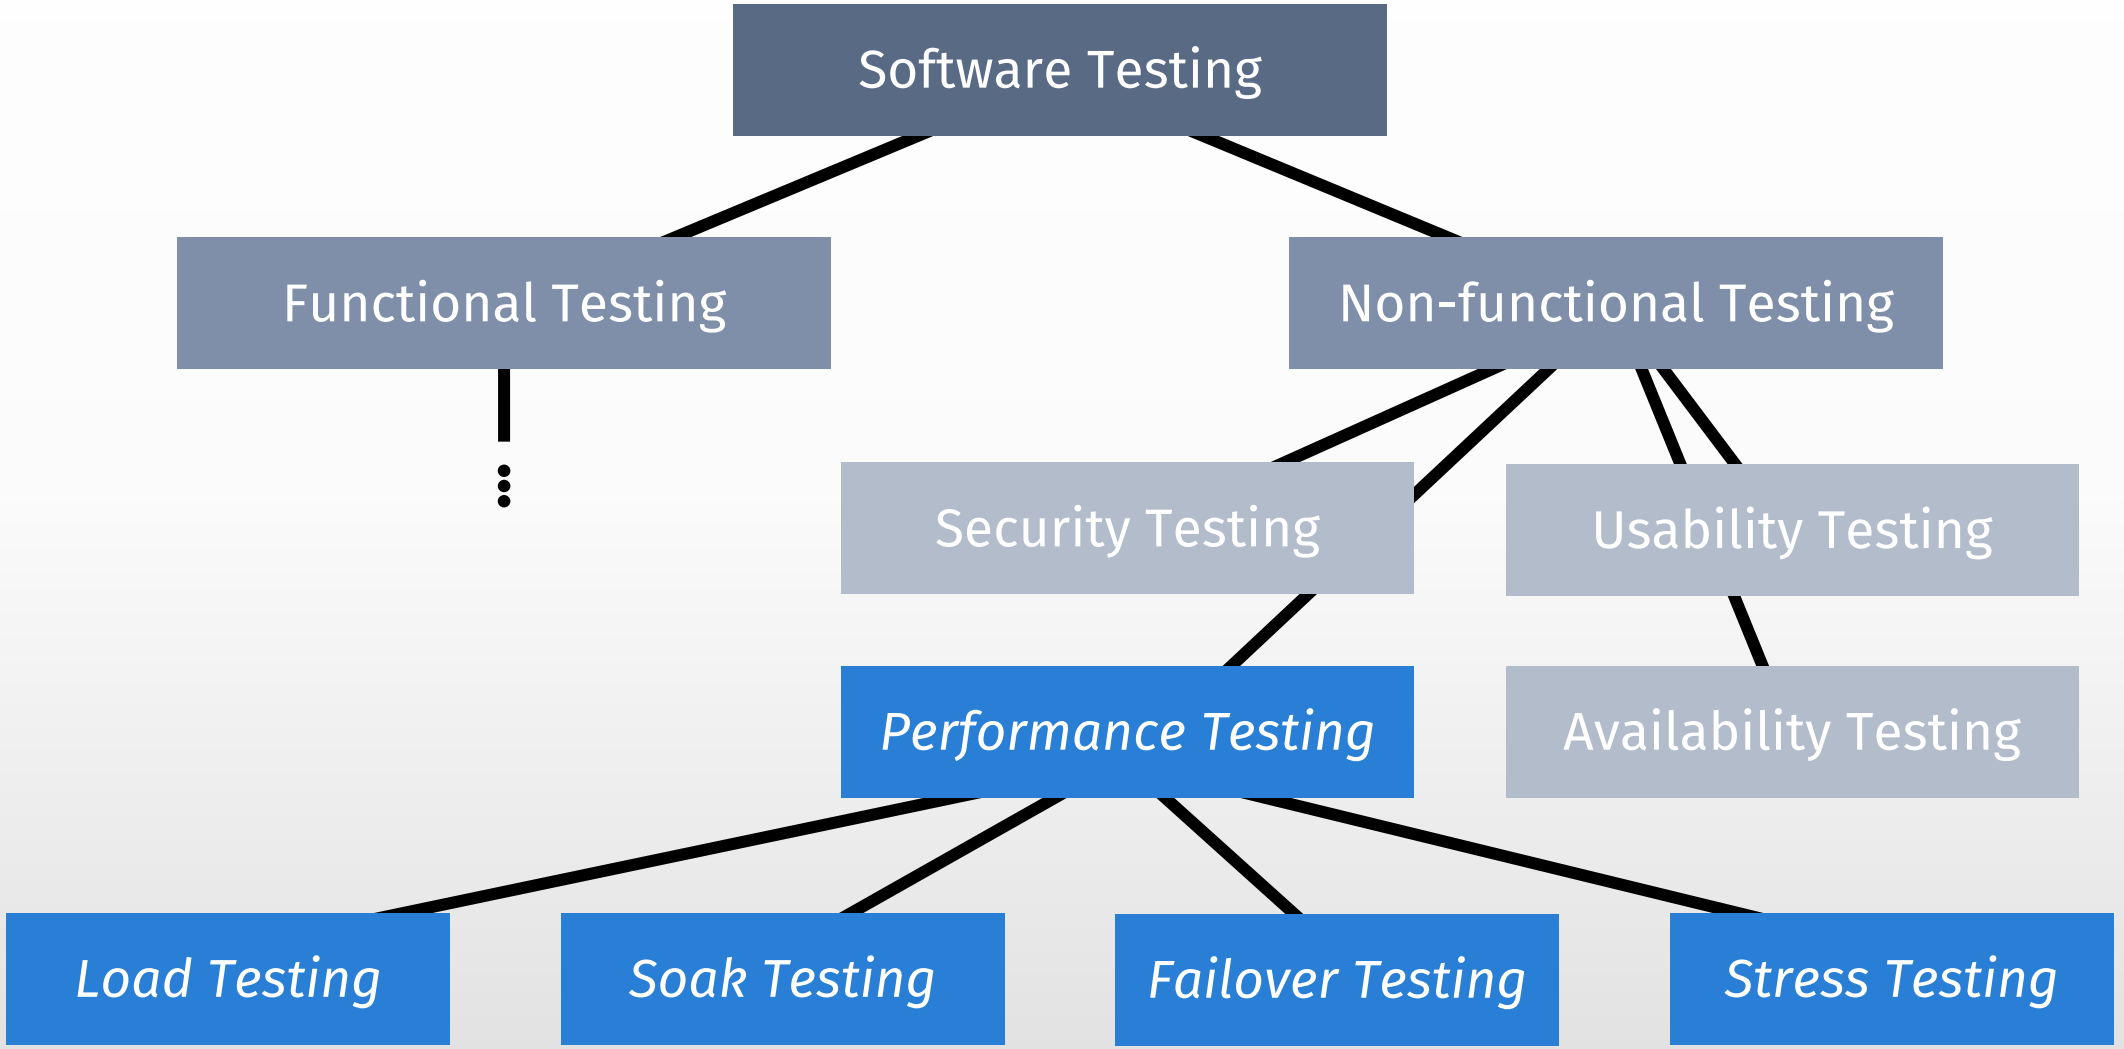

Arten von Performance-Tests

Load Test *(Lasttest)*

Analyse der Performance unter einer *konstanten*, *definierten* Last

- Z. B. Antwortzeiten, Durchsatz, Ressourcenverbrauch

Ziel: Sicherstellen, dass Leistung unter erwarteten Last ausreichend ist

Wird z. B. vor dem Live-Schalten einer App oder vor erwarteter Zunahme der Last gemacht

Soak Test *(Dauerlasttest)*

Untersuchen der Performance *über längeren Zeitraum hinweg*

- Z. B. 12 Stunden oder mehrere Tage

Ziel: Identifizieren von Memory Leaks oder anderen Anomalitäten

Failover Test

Lasttest bei (manuell verursachtem) Ausfall von Systemkomponenten

Ziele:

- Sicherstellen, dass Failover zuverlässig funktioniert
- Analyse von Performance während/nach Failover (z. B. zusätzlicher Ressourcenverbrauch)

Stress Test

Schrittweises Erhöhen der Last, solange bis System instabil wird oder komplett ausfällt

Ziel: Verstehen des Verhaltens des Systems unter extremer Last

Stressverhalten von Applikationen

Konkrete Fragen beim Stresstesten:

- Wie ändert sich Antwortzeit-Verhalten?
- Wie gross ist maximale Last, ohne dass System unzuverlässig wird?
- Zeigt System unerwartetes Verhalten?

Stressverhalten: Welche Effekte können auftreten?

- Einzelne Aussetzer ➞ Einfluss auf Verfügbarkeit (SLA!)
- Totalausfall
- Datenverlust/-Inkonsistenz
- Failover
- Kettenreaktion durch Failover

Allgemein: Lastverhalten

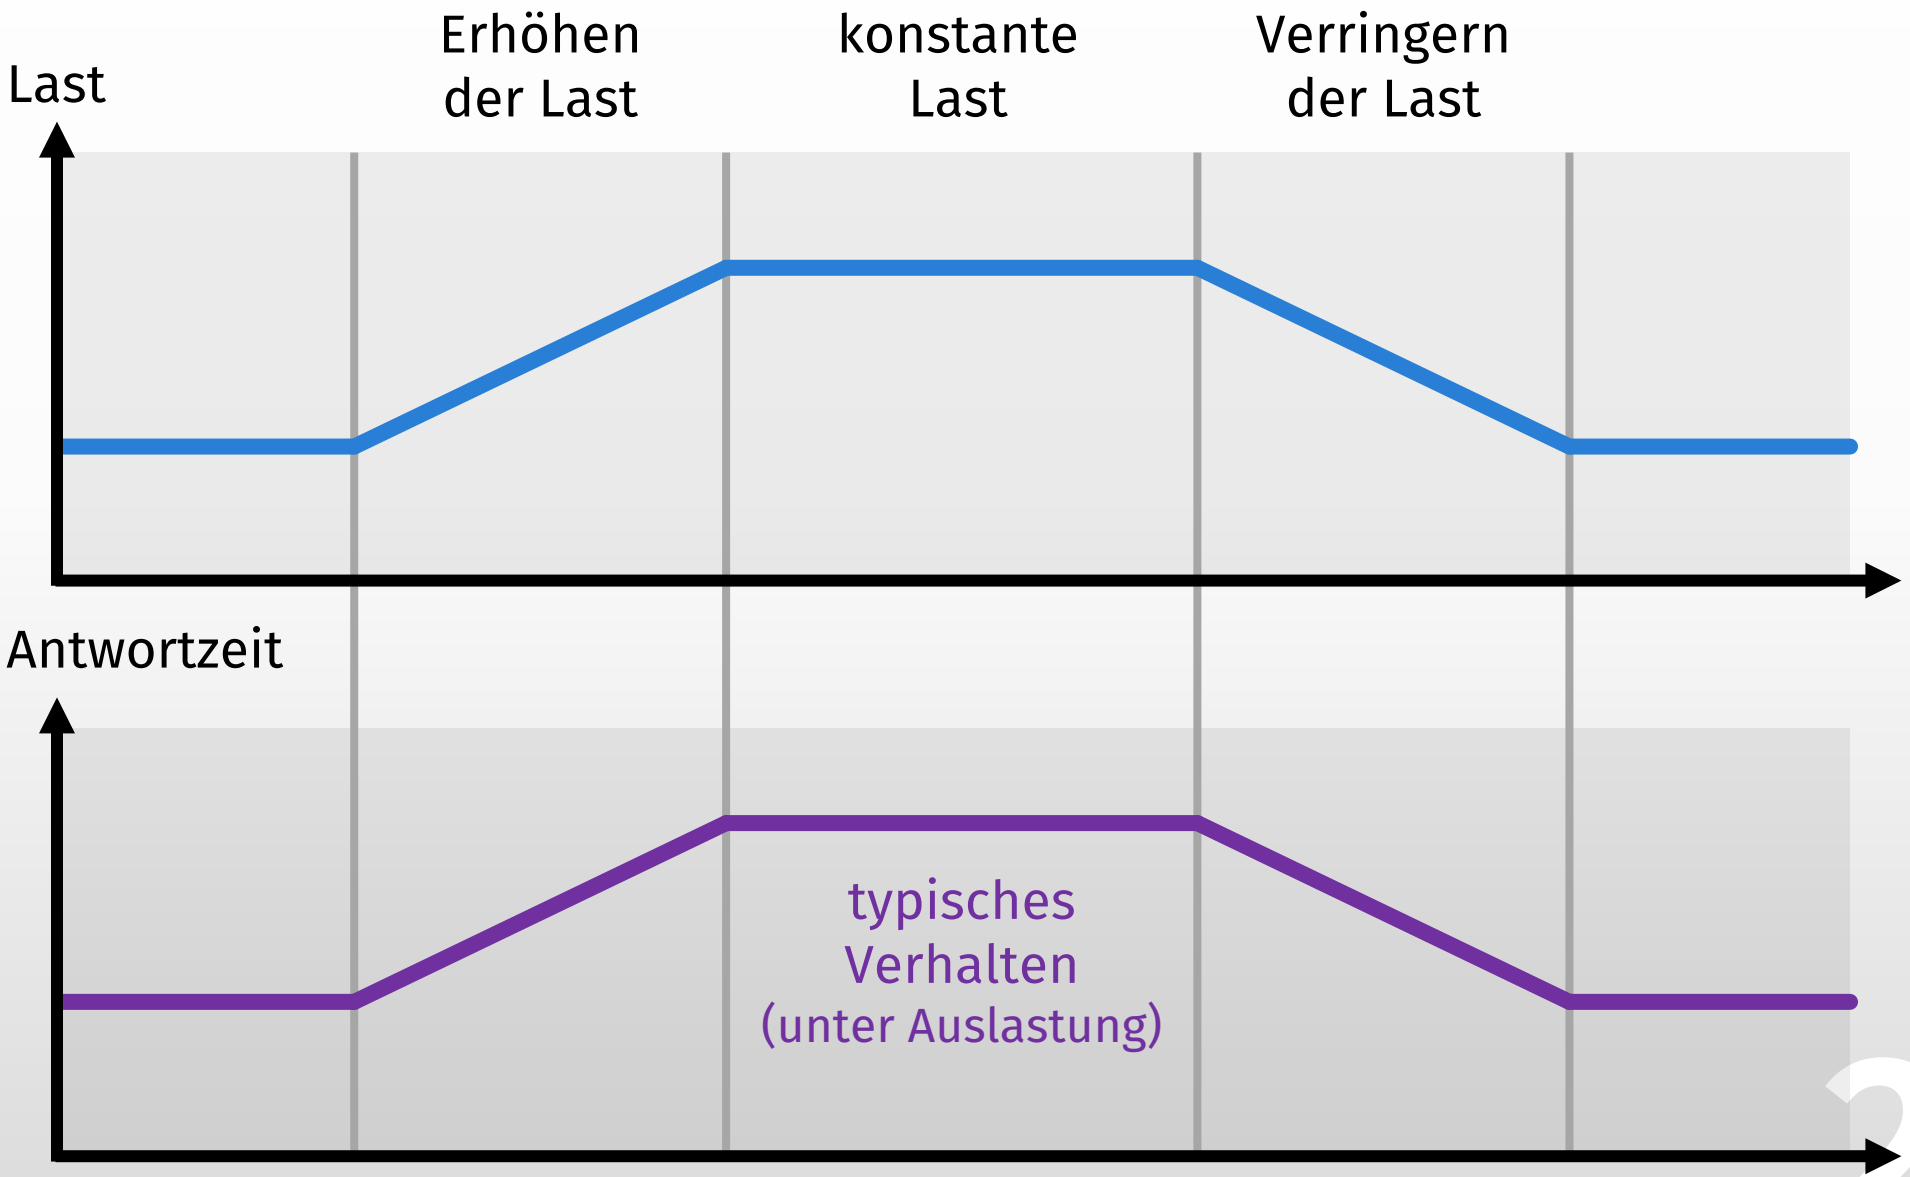

Erhöhen der Last

«Spikes» / «Peaks»

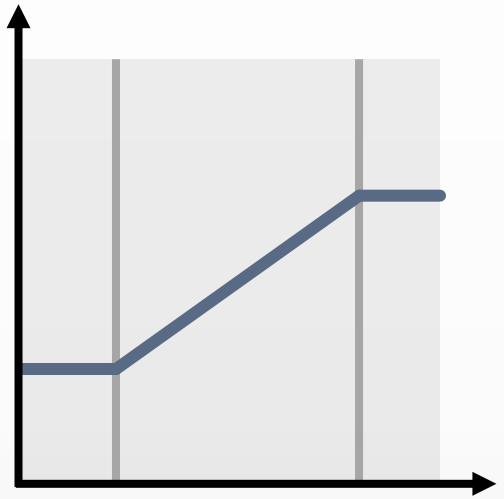

typisches Verhalten

Erhöhen der Last

«Verzögertes Ramp-Up»

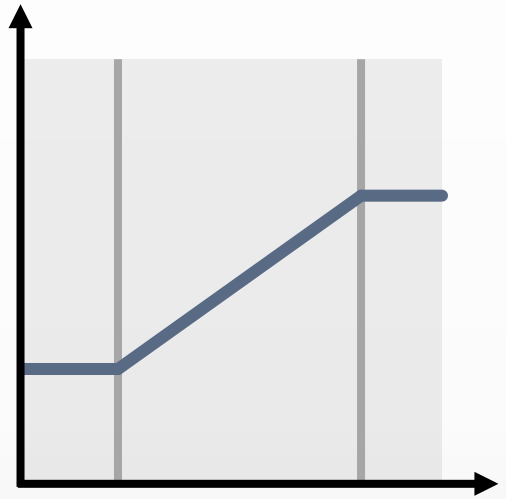

typisches Verhalten

Erhöhen der Last

Verbesserung!

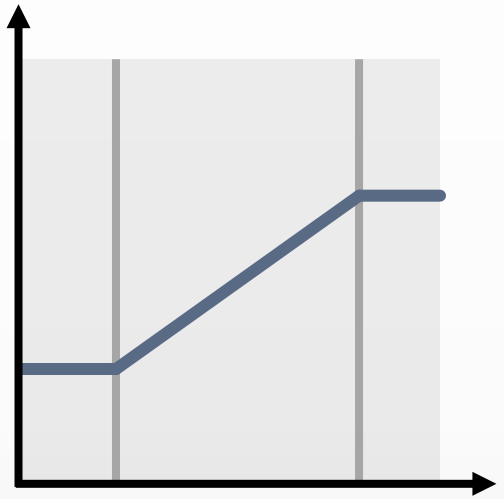

typisches Verhalten

Konstante Last

Langsame Verschlechterung

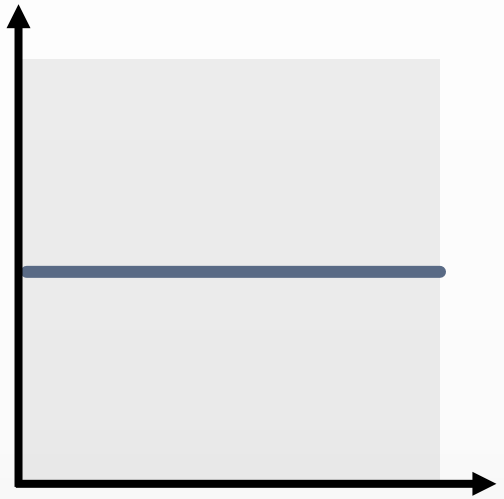

typisches Verhalten

Konstante Last

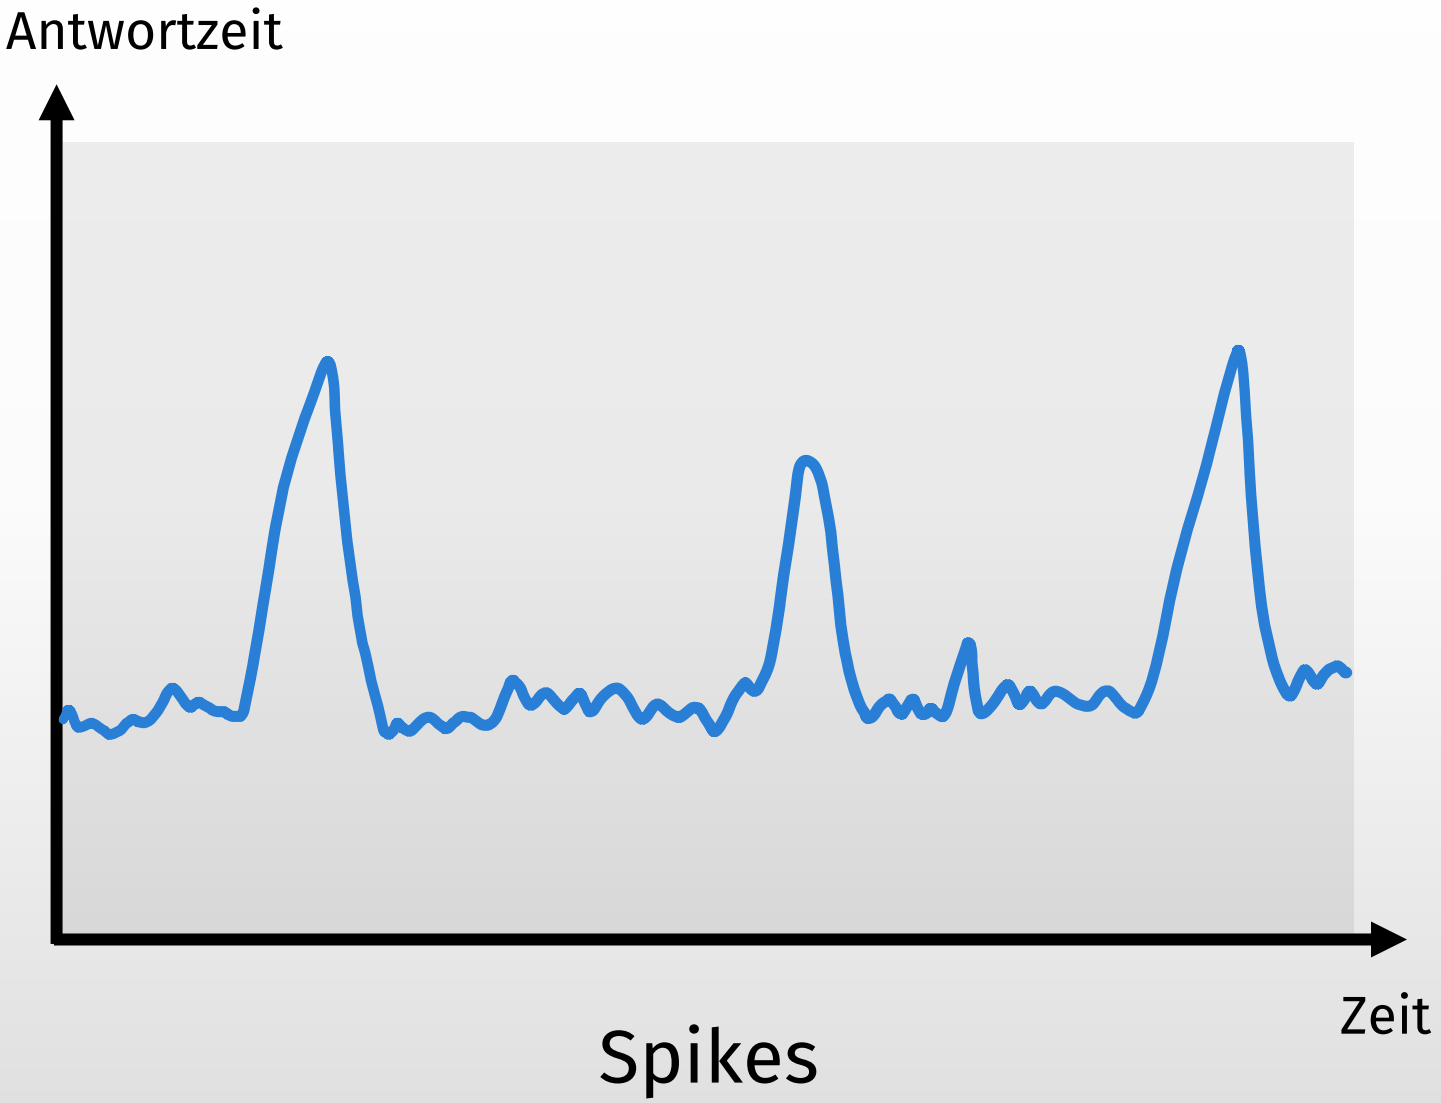

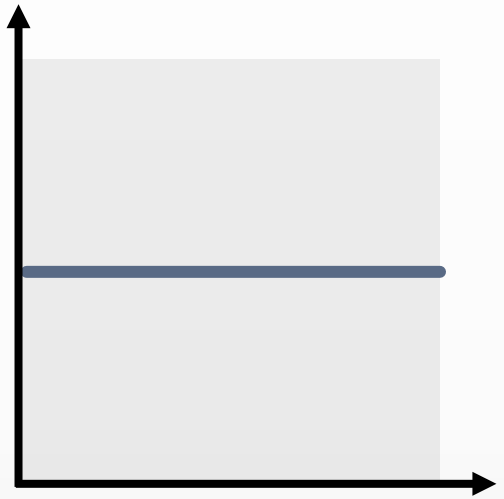

typisches
Verhalten

Verringern der Last

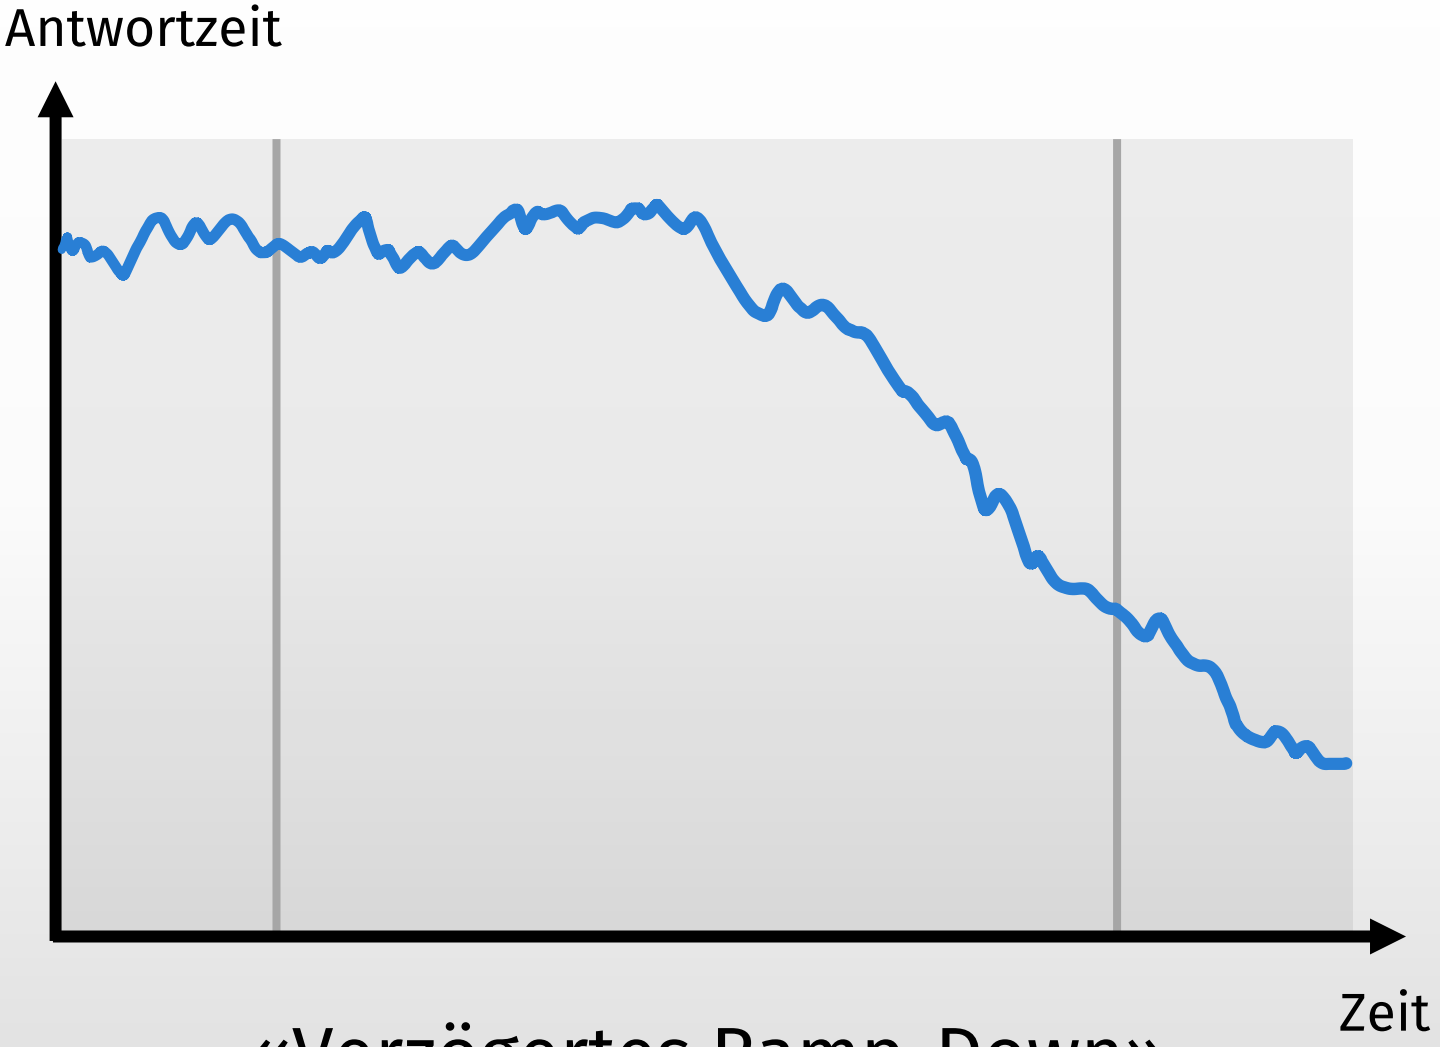

«Verzögertes Ramp-Down»

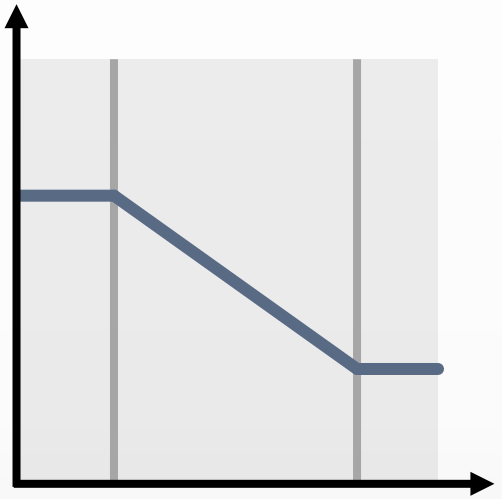

typisches Verhalten

Verringern der Last

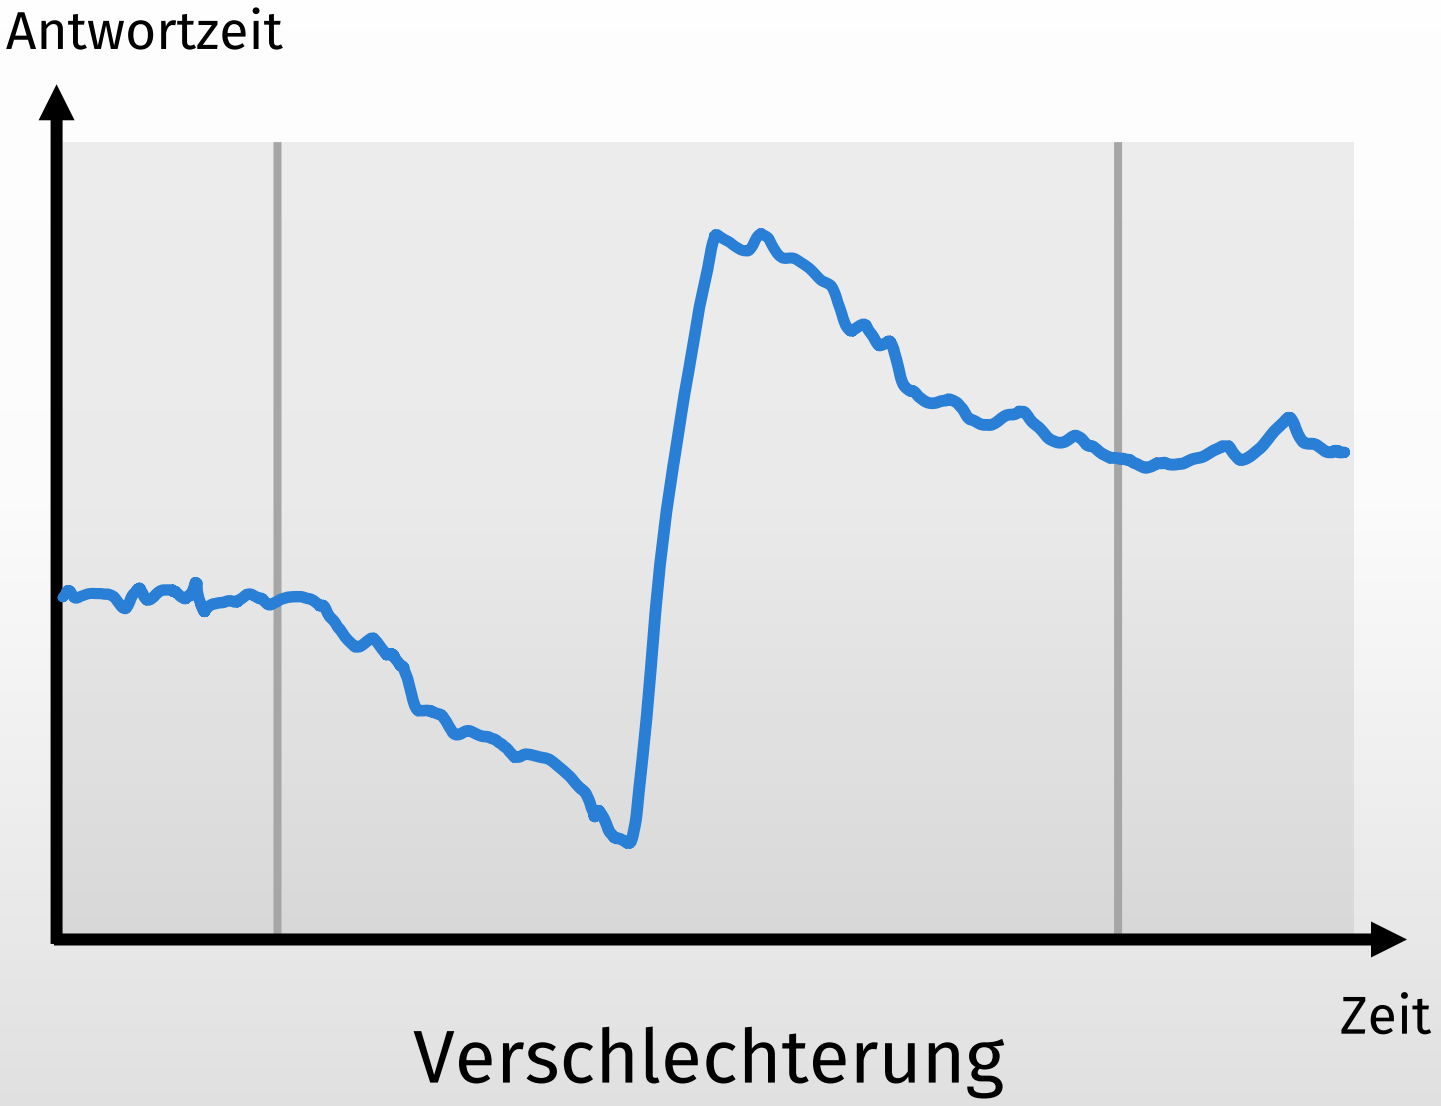

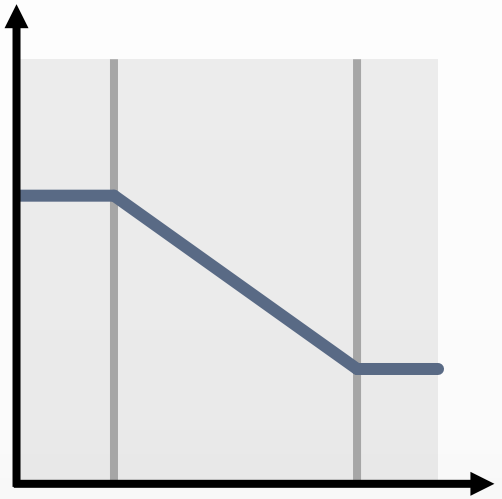

typisches Verhalten

Fragen?