Fachhochschule Nordwestschweiz
Hochschule für Technik

Application Performance Management

Caching

Michael Faes

Rückblick: Performance Testing

Lasttest: Analysieren der Leistung unter einer konstanten, definierten Last

Dauerlasttest: Untersuchen der Leistung über einen grösseren Zeitraum hinweg

Failover-Test: Lasttest bei (manuell verursachtem) Ausfall von System-Komponenten

Stresstest: Schrittweises Erhöhen der Last, bis System instabil wird oder ganz ausfällt

Übersicht Woche 12

1. Rückblick Performance Testing
2. Caching
   - Beispiele, Speicher-Hierarchie
   - Caching-Grundlagen
   - Cache-Algorithmen
3. Übung

Nochmals Zeitmassstäbe

Event	Latency	Scaled
1 CPU cycle	0.3 ns	1 s
Level 1 cache access	0.9 ns	3 s
Level 2 cache access	3 ns	10 s
Level 3 cache access	10 ns	33 s
Main memory access (DRAM, from CPU)	100 ns	6 min
Solid-state disk I/O (flash memory)	10–100 µs	9–90 hours
Rotational disk I/O	1–10 ms	1–12 months

!

Quelle:
Gregg (2020)

1. Zugriff auf Speicher dauert mehr als 100 Zyklen
2. Die meisten Instruktionen brauchen wohl Daten aus dem Speicher

Müsste CPU sich nicht während 99% der Zeit im Leerlauf befinden??

Nein! → *L1–L3-Caches*

Was ist ein Cache?

Cache: Schneller Speicher, der *wiederholte Zugriffe* auf ein langsame Ressource oder aufwändige Neuberechnungen zu vermeiden hilft.

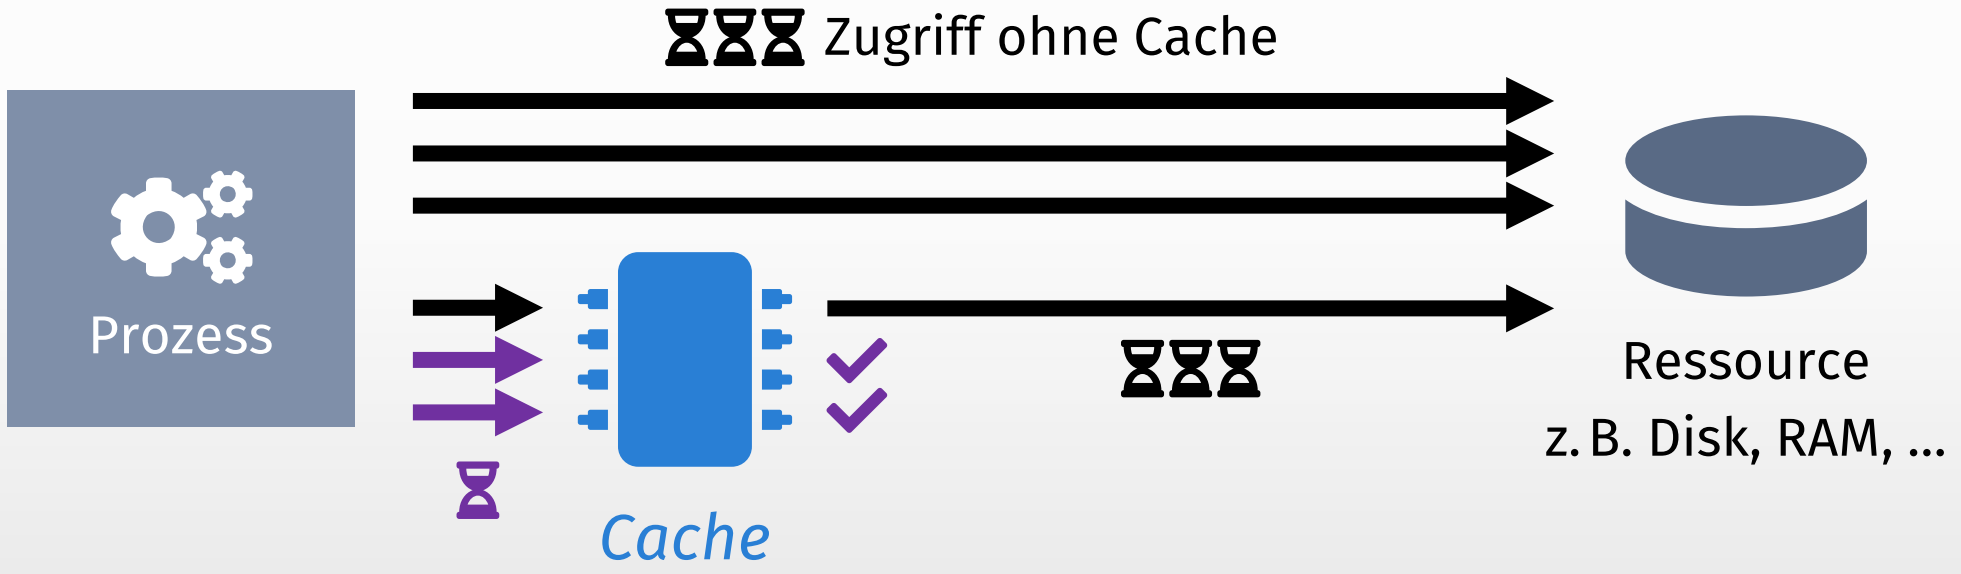

Daten bleiben im Cache, damit sie bei Bedarf schneller abrufbar sind.

Bringt nur etwas, wenn Cache deutlich schneller ist!

Speicher-Hierachie

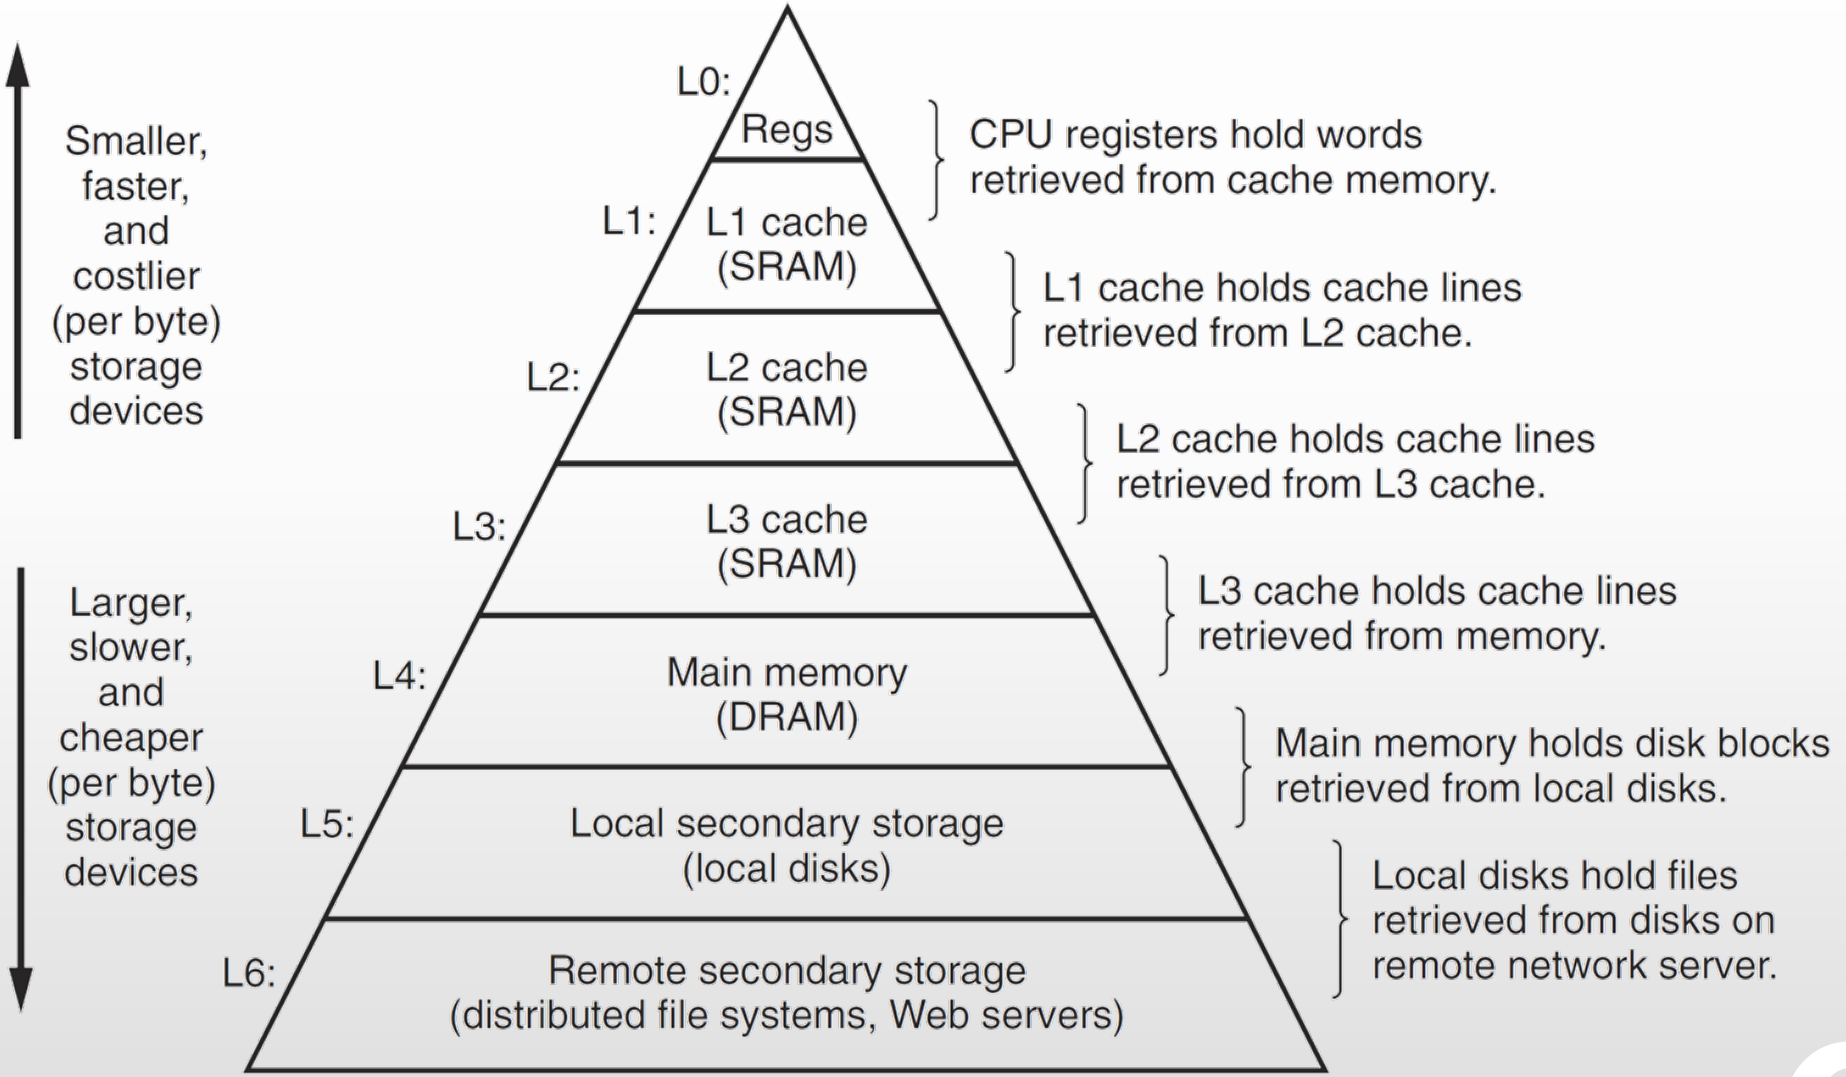

Bild: Bryant & O'Hallaron (2015)

Beispiele für Caches

Computersysteme

- CPU-Caches (L1–L3)
- Filesystem-Cache
- (Paging)
- Festplatten mit SSD-Caches

Applikationen

- *Memoization* (z. B. `hashCode`)
- Dynamic Programming
- App-spezifische Caches

Übung

Web

- HTTP (in Browser oder Proxy)
- DNS

Übung

- Code Cache für JIT (Java)
- Web-Cache von Google

Caching ist (manchmal) schwierig

“There are only two hard problems in Computer Science: cache invalidation and naming things.”

— Phil Karlton

“There are two hard problems in Computer Science: cache invalidation, naming things, and off-by-1 errors.”

“There are two hard problems in Computer Science: we only have one joke and it's not funny.”

Caching kann sehr effektiv sein!

Beispiel: *Performance Problems You Can Fix: A Dynamic Analysis of Memoization Opportunities*

dl.acm.org/citation.cfm?id=2814290

Memoization: Spezielle Form von Caching, Zwischenspeichern von berechneten Resultaten

Paper: Automatische Analyse findet Orte in Java-Code, wo Caches sinnvoll sein könnten. Resultate: Bis zu **12.9× Speedup**.

Allgemein: *Caching ist eine Technik, die praktisch **orthogonal** zu anderen Technologien und Optimierungen eingesetzt werden kann und oft sehr effektiv ist.*

Caching-Grundlagen

Caching-Begriffe

Cache Access: Lese-Zugriff auf Cache

Cache Hit: Element wurde in Cache gefunden

Cache Miss: Element wurde *nicht* in Cache gefunden

Hit Ratio (Miss Ratio): Anteil der Zugriffe, die zu Cache Hit (Miss) führen

- Hohe Hit Ratio: Cache ist «hot», sonst «cold»

Füllstand: Anteil des verwendeten Platzes im Cache

Ist ein Cache «gut», wenn er voll oder leer ist?

Falsche Frage! Leistung des Caches hängt von Hotness ab, nicht von Füllstand! (Wobei komplett leerer Cache natürlich nichts bringt.)

Warum funktionieren Caches?

Principle of Locality

- *Temporal locality*: Wenn ein Objekt verwendet wird, wird es *mit grosser Wahrscheinlichkeit bald* wieder verwendet.
- *Spatial locality* (*data locality*): Ebenso «benachbarte» Objekte (…)

Konkret: *Zipf's Law* (80:20-Regel):
80% aller Zugriffe gehen auf die 20% selben Objekte
(oder auch 90:10, usw.)

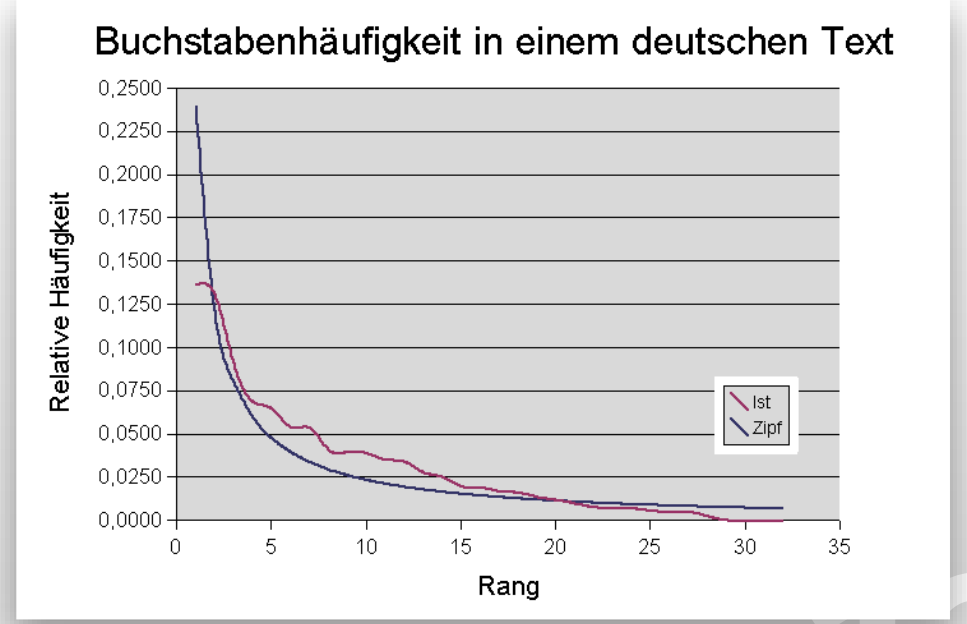

Bild: «Anton» (deutsche Wikipedia)

Spatial Locality & Cache Lines

CPU-Caches speichern keine einzelnen Bits oder Bytes, sondern grössere Speicher-Stücke: *Cache Lines*.

- Grösse typischerweise 64 oder 128 Bytes

Wenn CPU ein Byte vom Speicher anfragt, wird ganze Cache Line geladen:

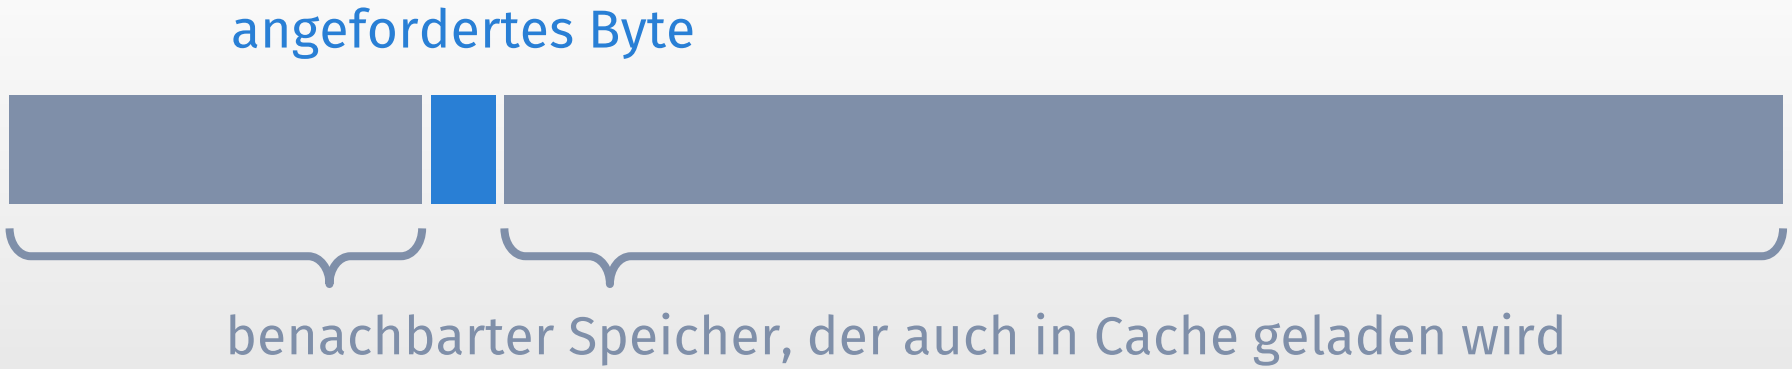

Grund: *Spatial Locality*. Daten, die kurz nacheinander verwendet werden, befinden sich oft nahe beieinander im Speicher. **Oder sollten!**

Spatial Locality: Beispiele

1

```
for (int i = 0; i < m; i++) {
    for (int j = 0; j < n; j++) {
        sum += array[i][j];
    }
}
```

2

```
for (int j = 0; j < n; j++) {
    for (int i = 0; i < m; i++) {
        sum += array[i][j];
    }
}
```

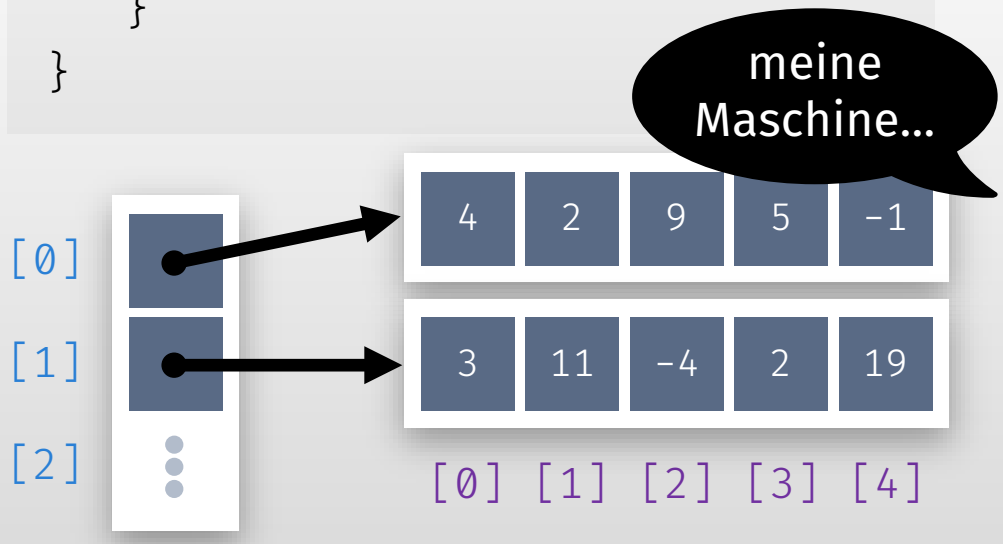

Wie verhalten sich die Code-Stücke im Bezug auf Locality?

1: gute Locality

2: schlechte Locality!

Werte innerhalb von (1D-)Array sind im Speicher benachbart!

Performance-Unterschiede:

1000 × 1000 `int`s: 4.6×

4000 × 4000 `byte`s: **22.0×** !

Wann lohnt sich ein Cache?

Parameter:

h	Hit Ratio
$m = 1 - h$	Miss Ratio
T_R	Zugriffs-Zeit auf Ressource
T_C	Zugriffs-Zeit auf Cache

Zeit ohne Cache: $T_{ohne} = T_R$

Zeit mit Cache: $T_{mit} = m \times T_R + T_C$

plus sekundäre Effekte!

Lohnt sich, wenn: $T_C \,/\, T_R < h$

Caching-Effektivität erhöhen

Ziel: Zugriffszeit mit Cache reduzieren: $T_{mit} = m \times T_R + T_C$

T_R und T_C sind typischerweise nicht einfach änderbar. Bleibt m…

Hit-/Miss-Ratio sind abhängig von:

- Cache-Grösse (Gesamtgrösse minus Metadaten)
- Zugriffsmuster
- *Cache-Algorithmus* (*Cache Replacement Policy*)

Möglichkeiten zum Erhöhen der Cache-Effektivität:

- Cache vergrössern (natürlich nicht bei Hardware-Caches…)
- Locality verbessern (Zugriffsmuster)
- **Cache-Algorithmus ändern!**

Cache-Algorithmen

(*Cache Replacement Policies*)

Cache-Algorithmen

Cache-Grösse ist begrenzt. Wenn Cache voll ist und neues Element gespeichert werden soll, muss mindestens 1 Element aus Cache entfernt werden. (Oder neues Element wird verworfen.)

Cache-Algorithmus: Bestimmt, welche Elemente entfernt werden

Theoretisch optimaler Cache-Algorithmus?

Bélády-Algorithmus: *Immer das Element entfernen, das in Zukunft am längsten nicht verwendet wird.*

- Unmöglich in der Praxis, aber kann verwendet werden, um **theoretisches Minimum von Cache Misses** zu bestimmen
- Erlaubt Vergleich mit echten Algorithmen

FIFO-Algorithmus

Gute **praktische** Algorithmen?

First-in–First-out

*Entfernt Element, das sich **am längsten im Cache** befindet*

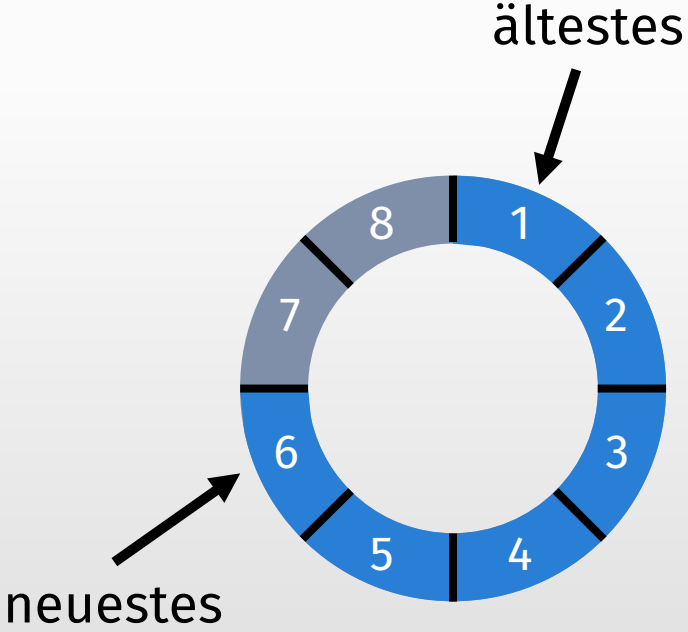

Warum?

- Einfache Heuristik für Locality by time
- Effiziente Implementation mit Ringbuffer: Braucht nur zwei Zeiger, für ältestes und neuestes Element

LRU-Algorithmus

Least Recently Used

*Entfernt Element, das am **längsten nicht gelesen** wurde*

Warum?

- «Echte» Locality by time (was aber selbst auch nur Heuristik ist!)

Muss aber für jedes Cache-Element Metadaten speichern, was nutzbare Cache-Grösse reduziert (Anzahl Elemente)

MRU-Algorithmus

Most Recently Used

*Entfernt Element, das **als letztes** gelesen wurde*

Warum???

- In gewissen Situation gilt Temporal Locality nicht!
  (Dafür aber vielleicht Spatial Locality)

Beispiel: Mehrmaliges Iterieren über Datensatz, der knapp nicht in Cache passt. LRU würde keinen einzigen Cache Hit landen, MRU viele!

LFU-Algorithmus

Least Frequently Used

*Entfernt Element, das **am wenigsten oft** gelesen wurde*

Warum?

- Allgemeine Heuristik: Vergangenheit ist aussagekräftig für Zukunft

Braucht Metadaten pro Element, wie LRU und MRU

Weitere: en.wikipedia.org/wiki/Cache_replacement_policies

RR-Algorithmus

Random Replacement

*Entfernt ein **zufälliges** Element*

Warum?

- Super-effizient und einfache Implementation ohne Metadaten
- Wahrscheinlichkeit, dass «wichtigstes» Element entfernt wird, ist klein, unabhängig von Zugriff-Muster!

Wurde wegen Einfachheit in CPU-Caches von ARM-Prozessoren verwendet

Fragen?